

**METODE TRANSFER LEARNING UNTUK KLASIFIKASI CITRA
HURUF TULIS TANGAN AKSARA JAWA**

SKRIPSI

Diajukan Untuk Memenuhi Salah Satu Syarat Memperoleh Gelar Sarjana Komputer
Program Studi Informatika



Diajukan oleh :

Paulus Caesario Dito Putra Hartono

205314159

**FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS SANATA DHARMA
YOGYAKARTA
2023**

HALAMAN PERSETUJUAN PEMBIMBING

SKRIPSI

**METODE *TRANSFER LEARNING* UNTUK KLASIFIKASI CITRA
HURUF TULIS TANGAN AKSARA JAWA**

Disusun oleh :

Paulus Caesario Dito Putra Hartono

NIM : 205314065

Dosen Pembimbing,

(Ir. Kartono Pinaryanto, S.T., M.Cs.)

Tanggal

HALAMAN PENGESAHAN

SKRIPSI

**METODE TRANSFER LEARNING UNTUK KLASIFIKASI CITRA
HURUF TULIS TANGAN AKSARA JAWA**

Dipersiapkan dan ditulis oleh

PAULUS CAESARIO DITO PUTRA HARTONO

NIM : 205314065

Telah dipertahankan di depan panitia penguji

Pada tanggal

Dan dinyatakan memenuhi syarat

SUSUNAN PANITIAN PENGUJI

JABATAN	NAMA LENGKAP	TANDA TANGAN
----------------	---------------------	---------------------

Ketua	:
-------	---	-------

Sekertaris	:
------------	---	-------

Anggota	:
---------	---	-------

Yogyakarta,

Fakultas Sains dan Teknologi

Universitas Sanata Dharma

Dekan,

Ir. Drs. Haris Sriwindono, M.Kom, Ph.D.

PERNYATAAN KEASLIAN KARYA

Saya menyatakan dengan sesungguhnya bahwa skripsi yang saya tulis ini tidak memuat karya atau bagian karya orang lain, kecuali yang telah disebutkan dalam kutipan dan daftar pustaka dengan mengikuti ketentuan sebagaimana layaknya karya ilmiah.

Apabila di kemudian hari ditemukan indikasi plagiarisme dalam naskah ini, saya bersedia menanggung segala sanksi sesuai peraturan perundang-undangan yang berlaku.

Yogyakarta, 24 November 2023

Penulis,

Paulus Caesario Dito Putra Hartono

**LEMBAR PERNYATAAN PERSETUJUAN
PUBLIKASI KARYA ILMIAH UNTUK KEPENTINGAN AKADEMIS**

Yang bertanda tangan di bawah ini, saya mahasiswi Universitas Sanata Dharma:

Nama : Paulus Caesario Dito Putra Hartono

Nomor Mahasiswa : 205314159

Demi pengembangan ilmu pengetahuan, saya memberikan kepada Perpustakaan Universitas Sanata Dharma karya ilmiah saya yang berjudul:

**METODE TRANSFER LEARNING UNTUK KLASIFIKASI CITRA
HURUF TULIS TANGAN AKSARA JAWA**

beserta perangkat yang diperlukan (bila ada). Dengan demikian, saya memberikan kepada Perpustakaan Universitas Sanata Dharma hak untuk menyimpan, mengalihkan dalam bentuk media lain, mengelolanya dalam bentuk pangkalan data, mendistribusikan secara terbatas, dan mempublikasikannya di Internet atau media lain untuk kepentingan akademis tanpa perlu meminta ijin dari saya maupun memerikan royalti kepada saya selama tetap mencantumkan nama saya sebagai penulis.

Atas kemajuan teknologi informasi, saya tidak berkeberatan jika nama, tanda tangan, gambar atau image yang ada di dalam karya ilmiah saya terindeks oleh mesin pencari (search engine), misalnya google.

Demikian pernyataan ini yang saya buat dengan sebenarnya.

Dibuat di Yogyakarta

Pada tanggal : 24 November 2023

Yang menyatakan,

Paulus Caesario Dito Putra Hartono

KATA PENGANTAR

DAFTAR ISI

HALAMAN PERSETUJUAN PEMBIMBING	i
HALAMAN PENGESAHAN.....	ii
PERNYATAAN KEASLIAN KARYA.....	iii
LEMBAR PERNYATAAN PERSETUJUAN PUBLIKASI KARYA ILMIAH	
UNTUK KEPENTINGAN AKADEMIS.....	iv
KATA PENGANTAR.....	v
DAFTAR ISI.....	vi
DAFTAR TABEL	x
DAFTAR GAMBAR	xi
ABSTRAK	xv
BAB I PENDAHULUAN.....	1
1.1. Latar Belakang	1
1.2. Rumusan Masalah.....	3
1.3. Batasan Masalah	3
1.4. Tujuan Penelitian	3
1.5. Manfaat Penelitian	4
BAB II TINJAUAN PUSTAKA.....	5
2.1. Aksara Jawa	5
2.2. Citra Digital	6

2.3.	Pengolahan Citra Digital	7
2.4.	Rescale/Resize	7
2.5.	Augmentasi Data.....	8
2.6.	Normalisasi dan Standardisasi	9
2.7.	Data Splitting	9
2.8.	Deep Learning.....	10
2.9.	Convolutional Neural Network.....	10
2.10.	Activation Functions.....	11
2.11.	Dropout	11
2.12.	Pooling	12
2.13.	Transfer Learning.....	13
2.14.	VGG Pre-trained Model.....	15
2.15.	Inception Pre-trained Model	17
2.16.	Xception Pre-trained Model.....	19
2.17.	Confusion Matrix	20
2.18.	Albumentations	20
2.19.	Tensorflow	20
2.20.	Review Literatur	21
BAB III METODE PENELITIAN		25
3.1.	Alur Penelitian	25
3.2.	Data	26

3.3.	Alat dan Bahan.....	31
3.3.1.	Spesifikasi Perangkat Keras.....	31
3.3.2.	Libraries	31
3.3.3.	Preprocessing	32
3.3.4.	Modeling	35
3.3.4.4.	Train.....	38
3.3.5.	Evaluasi.....	39
3.4.	Skenario Pengujian	40
BAB IV PENGUJIAN DAN ANALISIS		41
4.1.	Detail Skenario Pengujian.....	41
4.2.	Parameter Pengujian	42
4.3.	Matriks Kinerja	42
4.4.	Preprocessing Data.....	42
4.4.1.	Augmentasi	42
4.4.2.	Preprocessing Pipeline	45
4.5.	Modelling.....	46
4.5.1.	Pembuatan Model	46
4.5.2.	Pelatihan Model	48
4.6.	Analisis Hasil Pengujian	49
4.6.1.	Evaluasi Matriks Kinerja	50
4.6.2.	Evaluasi Parameter terhadap Matriks Kinerja.....	57

4.6.3. Evaluasi Top 10 Models.....	65
4.7. Percobaan Model dengan Data Baru.....	81
4.7.1. Parameter Pengambilan Model	82
4.7.2. Data	83
4.7.3. Hasil	87
BAB V PENUTUP.....	95
5.1. Kesimpulan	95
5.2. Saran	96
DAFTAR PUSTAKA.....	97

DAFTAR TABEL

Tabel 2.1 Review Literatur	21
Tabel 3.1 Skenario Pengujian	40
Tabel 4.1 Hasil Pelatihan Model berdasarkan Skenario Pengujian	49
Tabel 4.2 Hasil uji skenario tiap model diurutkan berdasarkan kolom Time	56
Tabel 4.3 Hasil uji skenario 10 model terbaik	65
Tabel 4.4 Rincian hasil percobaan baru menggunakan <i>top 10 models</i>	87
Tabel 4.5 Rincian hasil percobaan baru menggunakan <i>top 3 models</i>	88

DAFTAR GAMBAR

Gambar 2.1 Aksara Carakan	6
Gambar 2.2 <i>Rescale Bilinear Interpolation</i>	7
Gambar 2.3 Augmentasi Data.....	8
Gambar 2.4 Ilustrasi <i>max pooling</i>	12
Gambar 2.5 <i>Most common deep transfer learning approaches</i>	13
Gambar 2.6 Arsitektur VGG.....	16
Gambar 2.7 Arsitektur Inception	18
Gambar 2.8 Arsitektur Xception	19
Gambar 3.1 Alur Penelitian	25
Gambar 3.2 Alur Preprocessing.....	25
Gambar 3.3 Alur Modeling	26
Gambar 3.4 Data sumber pertama	27
Gambar 3.5 Data sumber kedua	28
Gambar 3.6 Data gabungan	29
Gambar 3.7 Data pengujian hasil pelatihan model.....	30
Gambar 3.8 Contoh rescale	32
Gambar 3.9 Contoh standardisasi	33
Gambar 3.10 Contoh augmentasi	34
Gambar 3.11 Contoh transfer learning	36
Gambar 3.12 Contoh pooling	37
Gambar 3.13 Contoh dropout	37

Gambar 3.14 Contoh confusion matrix	39
Gambar 4.1 Arsitektur Skenario	41
Gambar 4.2 <i>Source code config</i> augmentasi.....	43
Gambar 4.3 <i>Source code</i> fungsi augmentasi.....	44
Gambar 4.4 <i>Source code</i> fungsi <i>preprocessing pipeline</i>	45
Gambar 4.5 <i>Source code download pre-trained model Xception</i>	46
Gambar 4.6 <i>Summary Model Xception Full Freeze</i>	47
Gambar 4.7 <i>Source code</i> beserta <i>output</i> pelatihan tiap <i>epoch</i>	48
Gambar 4.8 Hasil keseluruhan skenario pengujian berdasarkan nilai akurasi test....	50
Gambar 4.9 Grafik Pelatihan Model VGG dengan stagnansi (<i>loss</i>).....	51
Gambar 4.10 Grafik Pelatihan Model VGG dengan stagnansi (<i>accuracy</i>)	52
Gambar 4.11 <i>Bar-chart</i> rerata akurasi tiap jenis model.....	53
Gambar 4.12 <i>Bar-chart</i> rerata akurasi tiap jenis model dengan filter	54
Gambar 4.13 <i>Bar-chart</i> jumlah model terfilter.....	54
Gambar 4.14 <i>Bar-chart</i> waktu pelatihan tiap model	55
Gambar 4.15 <i>Bar-chart</i> rerata waktu pelatihan tiap jenis model.....	55
Gambar 4.16 <i>Bar-chart</i> performa akurasi berdasarkan parameter augmentasi	57
Gambar 4.17 <i>Bar-chart</i> performa waktu berdasarkan parameter augmentasi.....	57
Gambar 4.18 <i>Bar-chart</i> performa akurasi berdasarkan parameter <i>freeze</i>	58
Gambar 4.19 <i>Bar-chart</i> performa waktu berdasarkan parameter <i>freeze</i>	59
Gambar 4.20 <i>Bar-chart</i> performa akurasi berdasarkan parameter <i>learning rate</i>	59
Gambar 4.21 <i>Bar-chart</i> performa waktu berdasarkan parameter <i>learning rate</i>	60
Gambar 4.22 <i>Bar-chart</i> performa akurasi berdasarkan parameter <i>layer</i>	61

Gambar 4.23 <i>Bar-chart</i> performa waktu berdasarkan parameter <i>layer</i>	61
Gambar 4.24 <i>Bar-chart</i> performa akurasi berdasarkan parameter <i>optimizer</i>	62
Gambar 4.25 <i>Bar-chart</i> performa waktu berdasarkan parameter <i>optimizer</i>	62
Gambar 4.26 <i>Correlation matrix</i> dari data hasil uji skenario	64
Gambar 4.27 <i>Bar-chart</i> performa akurasi set uji 10 model terbaik.....	67
Gambar 4.28 <i>Bar-chart</i> jumlah model berdasarkan parameter augmentasi	68
Gambar 4.29 <i>Bar-chart</i> jumlah model berdasarkan parameter <i>freeze</i>	68
Gambar 4.30 <i>Bar-chart</i> jumlah model berdasarkan parameter <i>learning rate</i>	69
Gambar 4.31 <i>Bar-chart</i> jumlah model berdasarkan parameter <i>layer</i>	70
Gambar 4.32 <i>Bar-chart</i> jumlah model berdasarkan parameter <i>optimizer</i>	71
Gambar 4.33 Grafik akurasi pelatihan 10 model terbaik.....	72
Gambar 4.34 Grafik akurasi validasi pelatihan 10 model terbaik	72
Gambar 4.35 Grafik <i>loss</i> pelatihan 10 model terbaik	73
Gambar 4.36 Grafik <i>validation loss</i> pelatihan 10 model terbaik.....	73
Gambar 4.37 <i>Bar-chart epoch</i> masing – masing 10 model terbaik	74
Gambar 4.38 Grafik rerata akurasi 10 model terbaik tiap <i>epoch</i>	75
Gambar 4.39 Grafik rerata akurasi validasi 10 model terbaik tiap <i>epoch</i>	76
Gambar 4.40 Grafik rerata <i>loss</i> 10 model terbaik tiap <i>epoch</i>	76
Gambar 4.41 Grafik rerata <i>validation loss</i> 10 model terbaik tiap <i>epoch</i>	76
Gambar 4.42 Grafik rerata akurasi validasi 10 model terbaik tiap <i>epoch</i> berdasar nilai parameter augmentasi	77
Gambar 4.43 Grafik rerata akurasi validasi 10 model terbaik tiap <i>epoch</i> berdasar nilai parameter <i>freeze</i>	78

Gambar 4.44 Grafik rerata akurasi validasi 10 model terbaik tiap <i>epoch</i> berdasar nilai parameter <i>learning rate</i>	78
Gambar 4.45 Grafik rerata akurasi validasi 10 model terbaik tiap <i>epoch</i> berdasar nilai parameter <i>layer</i>	78
Gambar 4.46 Grafik rerata akurasi validasi 10 model terbaik tiap <i>epoch</i> berdasar nilai parameter <i>optimizer</i>	79
Gambar 4.47 <i>Bar-chart</i> 3 model terbaik berdasarkan nilai tiap parameter <i>freeze</i>	82
Gambar 4.48 Data Aksara Jawa setelah di- <i>scan</i> dari kertas	83
Gambar 4.49 Data Aksara Jawa setelah di- <i>crop</i> menggunakan perangkat lunak	84
Gambar 4.50 Data Aksara Jawa setelah dilakukan <i>preprocessing</i>	85
Gambar 4.51 Data Aksara Jawa yang dihapus (<i>cleaning</i>)	86
Gambar 4.52 Rincian hasil percobaan baru menggunakan <i>top 10 models</i> dengan <i>bar-chart</i>	88
Gambar 4.53 Rincian hasil percobaan baru menggunakan <i>top 3 models</i> dengan <i>bar-chart</i>	89
Gambar 4.54 <i>Bar-chart</i> performa maksimum masing – masing model berdasarkan parameter <i>freeze</i>	90
Gambar 4.55 <i>Confusion matrix</i> dengan model id 66.....	91
Gambar 4.56 Visualisasi prediksi 20 data secara acak	92
Gambar 4.57 Visualisasi prediksi 20 data yang salah secara acak	93

ABSTRAK

Indonesia kaya akan warisan budaya, salah satunya adalah aksara Jawa yang menjadi bagian dari kekayaan budaya nasional. Namun, saat ini, tidak semua individu Jawa, khususnya generasi muda, memiliki kemampuan membaca aksara Jawa. Oleh karena itu, integrasi teknologi muncul sebagai solusi potensial untuk melestarikan warisan budaya ini. Deep learning, sebagai cabang dari machine learning, membuktikan diri sebagai alat penting dalam mengenali pola-pola rumit dalam data kompleks. Convolutional Neural Network (CNN) menonjol sebagai jaringan saraf yang efektif dalam bidang visi komputer, menunjukkan akurasi yang mendekati kemampuan manusia. Namun, efektivitas CNN sangat tergantung pada dataset yang besar. Untuk mengatasi keterbatasan data, metode transfer learning dapat digunakan untuk menanggulangi permasalahan ini. Penelitian ini berusaha mengimplementasikan dan mengidentifikasi model pra-latih optimal dari VGG, Inception, dan Xception untuk mengklasifikasikan citra huruf tulis tangan aksara Jawa. Hasil penelitian menunjukkan bahwa di antara ketiga model yang diuji, Inception V3 menunjukkan kinerja terbaik secara keseluruhan dalam hal akurasi, efisiensi komputasi, dan stabilitas hasil. Akurasi tertinggi yang dicapai adalah 100% pada dataset pengujian, meskipun terjadi penurunan ke sekitar 90% saat diuji dengan data baru yang sebelumnya belum pernah dilihat. Potensi untuk meningkatkan model masih terbuka lebar melalui penambahan variasi data, penyempurnaan *preprocessing pipeline*, dan penyesuaian *hyperparameter*.

Kata Kunci: *Transfer Learning*, Aksara Jawa, *Data Augmentation*, VGG, Inception, Xception

BAB I

PENDAHULUAN

1.1. Latar Belakang

Indonesia merupakan negara yang memiliki berbagai macam budaya, religi, dan bahasa. Jawa adalah salah satu pulau di Indonesia yang mempunyai populasi tinggi (Abdul Robby et al., 2019). Aksara jawa merupakan salah satu aksara tradisional Indonesia yang berkembang di pulau tersebut. Huruf tersebut masih dapat ditemukan di papan jalanan, tembok, atau peninggalan barang historikal. Aksara jawa juga dianggap sebagai warisan budaya nasional Indonesia. Namun, saat ini masyarakat menghadapi masalah di mana tidak semua orang Jawa dapat membaca aksara jawa, terutama generasi muda (Abdul Robby et al., 2019). Oleh karena itu, pengenalan aksara jawa melalui teknologi dapat menjadi salah satu solusi untuk melestarikan warisan budaya ini.

Salah satu teknologi yang dapat digunakan untuk pengenalan aksara jawa adalah *deep learning*. *Deep learning* merupakan salah satu cabang dari *machine learning* yang dapat digunakan untuk mengenali pola dari data yang kompleks (Lecun et al., 2015). Dalam hal ini, *deep learning* dapat digunakan untuk mengenali pola dari aksara jawa. Berbagai penelitian terkait klasifikasi citra terkhususnya citra tulis tangan telah dilakukan dan menghasilkan akurasi 83% (Ahmed et al., 2022). *Deep learning* telah secara dramatis meningkatkan standar terbaik dalam *speech recognition*, *visual object recognition*, *object*

detection dan banyak domain lainnya seperti *drug discovery* dan *genomics* (Lecun et al., 2015).

Convolutional Neural Network (CNN) yang merupakan salah satu jenis *network* atau jaringan pada *deep learning*, telah menjadi *representative neural networks* pada bidang *computer vision* karena performa yang dihasilkan dari *network* tersebut hampir menyentuh *human level accurate* (Chandrarathne et al., 2020; Li et al., 2022). Namun hal tersebut dapat berhasil karena terdapat dataset yang besar (He et al., 2015).

Untuk mengatasi masalah limitasi data, metode *transfer learning* telah berhasil mengatasi masalah keterbatasan data dengan mentransfer pengetahuan yang dipelajari dari satu domain aplikasi ke domain lain yang relevan (Yosinski et al., 2014). Dalam praktiknya, cara umum dari *deep transfer learning* adalah menggunakan CNN yang telah dilatih sebelumnya sebagai model sumber, yang dilatih dengan data dalam jumlah besar seperti ImageNet (Deng et al., 2010). Beberapa model sumber tersebut antara lain adalah Xception, Inception, dan VGG.

Penelitian yang serupa pada bidang citra tulis tangan juga sudah dilakukan oleh berbagai peneliti lainnya. Pada penelitian terdahulu metode *transfer learning* telah menghasilkan akurasi 98% pada citra aksara jawa dan 91% pada citra aksara sunda (Kesaulya et al., 2022; Khalifa et al., 2022). Dari penemuan tersebut, peneliti akan mencoba mengimplementasikan dan mencari

pre-trained model mana yang terbaik dari Xception, Inception, dan VGG untuk klasifikasi citra huruf tulis tangan aksara jawa.

1.2. Rumusan Masalah

1. Bagaimana cara melakukan implementasi *transfer learning* pada kasus citra huruf tulis tangan aksara jawa?
2. Berapa akurasi yang diperoleh dari metode *transfer learning*?
3. Dari ketiga *pre-trained* model yang penulis ambil, manakah yang terbaik?

1.3. Batasan Masalah

1. Penelitian ini difokuskan untuk klasifikasi pada citra huruf tulis tangan aksara jawa
2. Metode yang digunakan adalah *transfer learning* menggunakan 3 *pre-trained* model yaitu Xception, Inception, dan VGG
3. Data yang digunakan adalah citra huruf tulis tangan aksara jawa tanpa pasangan atau aksara carakan (nglegena)
4. Penelitian ini berfokus untuk mencari *pre-trained* model terbaik dari ketiga model yang diambil penulis

1.4. Tujuan Penelitian

1. Mengklasifikasikan citra huruf tulis tangan aksara jawa (carakan) dengan jumlah total 20 jenis huruf menggunakan metode *transfer learning*
2. Mengevaluasi ketiga *pre-trained* model yang digunakan oleh penulis

1.5. Manfaat Penelitian

1. Mengetahui performa *pre-trained* model terbaik yang diambil oleh penulis, untuk kasus citra huruf aksara Jawa
2. Membantu orang awam untuk mengenali aksara Jawa
3. Dapat digunakan penulis lain untuk pengembangan penelitian lebih lanjut

BAB II

TINJAUAN PUSTAKA

Bab ini menjelaskan tentang definisi dan teori-teori yang digunakan sebagai landasan penelitian yang berasal dari hasil publikasi dan penelitian dan/atau buku yang relevan.

2.1. Aksara Jawa

Aksara Jawa, yang juga dikenal sebagai Hanacaraka dan Dentawyanjana, adalah salah satu aksara tradisional di Indonesia yang berkembang di Pulau Jawa. Aksara ini terutama digunakan untuk menulis bahasa Jawa, tetapi juga digunakan untuk menulis beberapa bahasa daerah lainnya seperti bahasa Sunda, Madura, Sasak dan Melayu serta bahasa historis seperti Sanskerta dan Kawi. Aksara Jawa berasal dari aksara Brahmi India melalui aksara Kawi dan berkerabat dekat dengan aksara Bali. Aksara ini aktif digunakan dalam sastra dan tulisan sehari-hari oleh masyarakat Jawa dari pertengahan abad ke-15 hingga pertengahan abad ke-20 sebelum perlahan-lahan digantikan oleh huruf Latin. Aksara ini masih diajarkan di DI Yogyakarta, Jawa Tengah, Jawa Timur, Cirebon dan Indramayu sebagai bagian dari muatan lokal, tetapi penggunaannya terbatas dalam kehidupan sehari-hari. Aksara Jawa merupakan sistem tulisan *abugida* yang terdiri dari sekitar 20 aksara dasar (Poerwadarminta, 1939; Everson, 2008).



Gambar 2.1 Aksara Carakan

sumber: <https://www.rukita.co/stories/aksara-jawa-lengkap/>

2.2. Citra Digital

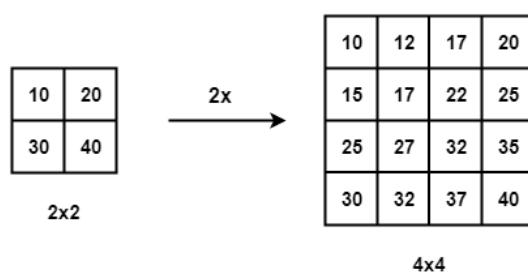
Citra digital terdiri dari sejumlah elemen terbatas, masing-masing memiliki lokasi dan nilai tertentu. Elemen-elemen ini disebut elemen citra, pel, dan piksel. Sebuah citra digital dapat didefinisikan sebagai fungsi dua dimensi, $f(x,y)$, di mana x dan y adalah koordinat spasial (bidang), dan amplitudo f pada setiap pasangan koordinat (x,y) disebut intensitas atau tingkat abu-abu citra di titik tersebut. Bidang pengolahan citra digital mengacu pada pengolahan citra digital dengan menggunakan komputer digital (Gonzalez & Woods, 2018)

2.3. Pengolahan Citra Digital

Pemrosesan citra adalah kumpulan teknik komputasi untuk menganalisis, meningkatkan, mengompres, dan merekonstruksi citra. Komponen utamanya meliputi impor, di mana sebuah citra ditangkap melalui pemindaian atau fotografi digital; analisis dan manipulasi citra yang dilakukan menggunakan berbagai aplikasi perangkat lunak khusus; serta output (misalnya, ke printer atau monitor). Pemrosesan citra memiliki berbagai aplikasi yang luas di berbagai bidang, termasuk astronomi, kedokteran, robotik industri, dan pemantauan jarak jauh oleh satelit (Gonzalez & Woods, 2018).

2.4. Rescale/Resize

Proses *rescale/resize* pada citra merupakan tahap pra-pemrosesan yang kritis dalam visi komputer. Secara prinsip, model *deep learning* dapat dilatih lebih cepat pada citra berukuran kecil. Citra input yang lebih besar memerlukan jaringan saraf untuk belajar dari empat kali lipat jumlah piksel, yang pada akhirnya meningkatkan waktu pelatihan untuk arsitektur tersebut (Saponara & Elhanashi, 2022).




Gambar 2.2 *Rescale Bilinear Interpolation*

sumber: <https://theailearner.com/2018/12/29/image-processing-bilinear-interpolation/>

2.5. Augmentasi Data

Tujuan dari augmentasi data adalah menambahkan titik data baru ke ruang input dengan memodifikasi citra pelatihan sambil mempertahankan informasi semantik dan label target. Oleh karena itu, augmentasi data digunakan untuk mengurangi *overfitting*. Beberapa penelitian mengkonfirmasi pentingnya augmentasi data baik dalam pelatihan maupun pengujian, dan menunjukkan bahwa hal tersebut dapat menghasilkan peningkatan kinerja yang lebih besar daripada mengumpulkan citra sebagai dataset baru (Perez et al., 2018).



Gambar 2.3 Augmentasi Data

sumber: <https://analyticsindiamag.com/image-data-augmentation-impacts-performance-of-image-classification-with-codes/>

2.6. Normalisasi dan Standardisasi

Normalisasi dan standarisasi citra adalah proses yang digunakan dalam pemrosesan citra untuk memastikan perbandingan yang optimal antara metode akuisisi data dan instansi tekstur. Tujuan utama dari normalisasi dan standarisasi citra adalah mengubah piksel citra sehingga mereka dapat dibandingkan secara konsisten dalam berbagai situasi (Gonzalez & Woods, 2018).

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)} \quad (2.1)$$

$$x' = \frac{x - \bar{x}}{\sigma} \quad (2.2)$$

2.7. Data Splitting

Data splitting atau pemisahan data melibatkan pembagian dataset menjadi tiga bagian: set pelatihan, set validasi, dan set pengujian. Set pelatihan digunakan untuk membangun model, sementara set validasi dan pengujian berfungsi sebagai set penahanan. Tidak ada proporsi yang pasti untuk pembagian dataset ini, namun aturan umum sebelumnya adalah 70% untuk pelatihan dan 15% untuk validasi dan pengujian. Akan tetapi, dalam era *big data*, proporsi seperti 95% untuk pelatihan dan 2,5%/2,5% untuk validasi/pengujian dapat dipertimbangkan. Dengan menggunakan ketiga subset ini, diharapkan model yang dibangun dapat memprediksi dengan baik contoh-contoh yang tidak dilihat oleh algoritma pembelajaran. Set validasi digunakan untuk memilih algoritma pembelajaran dan menentukan

nilai *hyperparameter* terbaik, sementara set pengujian digunakan untuk mengevaluasi model sebelum digunakan di lapangan (Burkov, 2019).

2.8. Deep Learning

Deep learning adalah cabang dari *machine learning* yang menggunakan jaringan saraf tiruan dengan banyak lapisan tersembunyi untuk memodelkan data yang kompleks (Lecun et al., 2015). Teknik ini memungkinkan komputer untuk mempelajari representasi data yang abstrak dan hierarkis secara otomatis dari data mentah, tanpa perlu pengetahuan domain yang spesifik atau rekayasa fitur yang rumit. *Deep learning* telah mencapai hasil yang sangat baik dalam berbagai tugas pengenalan pola, termasuk pengenalan suara, pengenalan gambar, dan pemrosesan bahasa alami.

2.9. Convolutional Neural Network

Convolutional Neural Network (CNN) adalah jenis *network* khusus yang secara signifikan mengurangi jumlah parameter dalam *deep neural network* dengan banyak unit tanpa kehilangan terlalu banyak kualitas model. CNN telah menemukan aplikasi dalam pengolahan gambar dan teks di mana mereka mengalahkan banyak patokan yang sebelumnya ditetapkan (Burkov, 2019). Dalam implementasi *transfer learning*, CNN bertugas sebagai mengekstrak fitur dari citra data pada model tersebut.

2.10. Activation Functions

Untuk memungkinkan jaringan saraf mempelajari batas keputusan yang kompleks, diterapkan fungsi aktivasi non-linier pada beberapa lapisannya. Fungsi yang umum digunakan meliputi *tanh*, *ReLU*, *softmax*, dan varian dari fungsi-fungsi tersebut. Secara teknis, setiap neuron menerima sinyal masukan yang merupakan jumlah terbobot dari bobot sinaptik dan nilai aktivasi dari neuron yang terhubung (Zaccone & Karim, 2018).

$$relu(z) = \begin{cases} 0 & \text{if } z < 0 \\ z & \text{otherwise} \end{cases} \quad (2.3)$$

$$softmax(z)_j = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}} \text{ for } j = 1, \dots, K \quad (2.4)$$


2.11. Dropout

Dropout adalah teknik yang digunakan untuk mengurangi *overfitting* dalam jaringan dengan banyak lapisan dan/atau neuron. Secara umum, lapisan *dropout* ditempatkan setelah lapisan yang memiliki sejumlah besar neuron yang dapat dilatih (Zaccone & Karim, 2018).

Teknik ini mengubah pendekatan pembelajaran bobot. Alih-alih mempelajari semua bobot jaringan bersama-sama, *dropout* melatih sebagian dari mereka dalam iterasi pelatihan *batch* (Ranjan, 2019).

2.12. Pooling

Fungsi *pooling* dalam *deep learning* adalah untuk mengurangi jumlah koefisien peta fitur yang diproses. Ini dicapai melalui *downsampling*, yang mengurangi dimensi spasial dari input. *Pooling* juga membantu menginduksi hirarki filter spasial dengan membuat lapisan konvolusi berturut-turut melihat jendela yang semakin besar dari segi fraksi input asli yang mereka tutupi. *Max pooling* (salah satu jenis *pooling*) cenderung bekerja lebih baik daripada metode *downsampling* lainnya, seperti *average pooling* atau menggunakan *strides* di lapisan konvolusi sebelumnya, karena lebih informatif untuk melihat kehadiran maksimal fitur yang berbeda daripada kehadiran rata-rata tersebut (Chollet, 2021).




Gambar 2.4 Ilustrasi *max pooling*

sumber: <https://paperswithcode.com/method/max-pooling>

2.13. Transfer Learning

Transfer learning adalah peningkatan pembelajaran dalam tugas baru melalui transfer pengetahuan dari tugas terkait yang sudah dipelajari (Torrey & Shavlik, 2009). *Transfer learning* terdiri dari mengambil jaringan yang sudah dibangun dan membuat perubahan yang sesuai pada parameter dari berbagai lapisan sehingga dapat menyesuaikan dengan dataset lain (Zaccone & Karim, 2018).



Gambar 2.5 Most common deep transfer learning approaches
(Iman et al., 2023)

Pendekatan populer pertama adalah menyesuaikan model yang telah dilatih pada data target, hal ini merupakan metode *Deep Transfer Learning* (DTL) yang paling umum digunakan karena kemudahannya. Metode ini dapat meningkatkan pelatihan pada data target dengan mengurangi biaya pelatihan dan mengatasi kebutuhan dataset target yang luas, tetapi masih rentan terhadap pelupakan yang mematikan. Metode ini telah diterapkan pada dataset gambar dan tabular di berbagai bidang. Pendekatan populer kedua adalah membekukan lapisan CNN dalam model yang telah dilatih dan menyesuaikan hanya lapisan terhubung sepenuhnya lateral. Dalam metode

ini, lapisan CNN mengekstrak fitur dari dataset yang diberikan, dan *fully connected layer* bertanggung jawab untuk klasifikasi dan akan disesuaikan dengan tugas baru untuk data target (Iman et al., 2022).

2.14. VGG Pre-trained Model

Visual Geometric Group (VGG) adalah model arsitektur jaringan saraf tiruan yang sangat dalam dan dikembangkan oleh Visual Geometry Group di Universitas Oxford (Simonyan & Zisserman, 2014). Model ini terdiri dari beberapa lapisan konvolusi yang diikuti oleh lapisan *max-pooling* dan beberapa lapisan sepenuhnya terhubung di bagian akhir. Salah satu keunggulan utama dari model VGG adalah penggunaan filter konvolusi berukuran kecil (3×3) di semua lapisannya, yang memungkinkan jaringan untuk memiliki kedalaman yang lebih besar dengan jumlah parameter yang sama dibandingkan dengan jaringan yang menggunakan filter konvolusi berukuran lebih besar. Model VGG mencapai hasil yang sangat baik pada *benchmark* klasifikasi ILSVRC 2012 dan telah digunakan secara luas sebagai titik awal untuk berbagai tugas pengenalan gambar.

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224×224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

Gambar 2.6 Arsitektur VGG

(Simonyan & Zisserman, 2014)

2.15. Inception Pre-trained Model

Inception adalah model arsitektur jaringan saraf tiruan yang digunakan untuk visi komputer. Model ini dirancang untuk meningkatkan kualitas jaringan dengan cara yang efisien secara komputasi dengan menggunakan konvolusi yang difaktorkan dan regularisasi agresif (Szegedy et al., 2015). Inception-v3 adalah salah satu versi dari model Inception yang mencapai kinerja tinggi pada *benchmark* klasifikasi ILSVRC 2012 dengan biaya komputasi yang relatif rendah dibandingkan dengan arsitektur yang lebih sederhana dan monolitik (Szegedy et al., 2016). Model ini juga menggunakan jumlah parameter yang lebih sedikit dan regularisasi tambahan dengan *classifier auxilary* yang dinormalisasi *batch* dan *label-smoothing* untuk melatih jaringan berkualitas tinggi pada set pelatihan berukuran relatif sedang (Szegedy et al., 2016).


type	patch size/stride or remarks	input size
conv	$3 \times 3 / 2$	$299 \times 299 \times 3$
conv	$3 \times 3 / 1$	$149 \times 149 \times 32$
conv padded	$3 \times 3 / 1$	$147 \times 147 \times 32$
pool	$3 \times 3 / 2$	$147 \times 147 \times 64$
conv	$3 \times 3 / 1$	$73 \times 73 \times 64$
conv	$3 \times 3 / 2$	$71 \times 71 \times 80$
conv	$3 \times 3 / 1$	$35 \times 35 \times 192$
$3 \times$ Inception	As in figure 5	$35 \times 35 \times 288$
$5 \times$ Inception	As in figure 6	$17 \times 17 \times 768$
$2 \times$ Inception	As in figure 7	$8 \times 8 \times 1280$
pool	8×8	$8 \times 8 \times 2048$
linear	logits	$1 \times 1 \times 2048$
softmax	classifier	$1 \times 1 \times 1000$

Gambar 2.7 Arsitektur Inception

(Szegedy et al., 2016)

2.16. Xception Pre-trained Model

Xception adalah arsitektur jaringan saraf konvolusional yang sepenuhnya didasarkan pada lapisan konvolusi terpisah secara mendalam (*depthwise separable convolution layers*). Arsitektur ini diusulkan sebagai perpanjangan dari arsitektur Inception, di mana modul Inception telah digantikan dengan konvolusi terpisah secara mendalam. Arsitektur Xception adalah tumpukan linier lapisan konvolusi terpisah secara mendalam dengan koneksi residual (Chollet, 2016).



Gambar 2.8 Arsitektur Xception

(Chollet, 2016)

2.17. Confusion Matrix

Confusion Matrix adalah tabel yang merangkum seberapa sukses model klasifikasi dalam memprediksi contoh yang termasuk dalam berbagai kelas. Salah satu sumbu dari *confusion matrix* adalah label yang diprediksi oleh model, dan sumbu lainnya adalah label sebenarnya. Dalam masalah klasifikasi biner, terdapat dua kelas (Burkov, 2019).

2.18. Albumentations

Albumentations adalah *library* Python untuk augmentasi citra yang cepat dan fleksibel. *Library* ini secara efisien mengimplementasikan berbagai operasi transformasi gambar yang kaya dan dioptimalkan untuk kinerja, sambil memberikan antarmuka augmentasi gambar yang ringkas namun kuat untuk berbagai tugas visi komputer, termasuk klasifikasi objek, segmentasi, dan deteksi (Buslaev et al., 2020).

2.19. Tensorflow

TensorFlow adalah antarmuka untuk mengekspresikan algoritma *machine learning* dan implementasi untuk menjalankan algoritma tersebut. Sistem ini fleksibel dan dapat digunakan untuk mengekspresikan berbagai macam algoritma. TensorFlow telah digunakan untuk penelitian dan penerapan sistem pembelajaran mesin di berbagai bidang. API TensorFlow dan implementasi referensi dirilis sebagai paket sumber terbuka pada November 2015 dan tersedia di www.tensorflow.org (Abadi et al., 2016).

2.20. Review Literatur

Tabel 2.1 Review Literatur

No	Judul	Penulis (Tahun)	Metode	Hasil
1	<i>Transfer Learning Implementation on Sundanese Script Recognition Using Convolutional Neural Network</i>	MUHAMMAD KHALIFA U, et al. (2022)	<i>Transfer learning</i> dengan <i>pre-trained</i> model dari dataset <i>alphabet</i> , <i>devanagari</i> , <i>arabic</i> , dan aksara jawa	Model <i>transfer learning</i> terbaik didapat dari <i>pre-trained</i> dataset <i>arabic</i> , mencapai akurasi 91,86% dan <i>loss</i> 0.2814
2	Javanese Script Text Image Recognition Using Convolutional Neural Networks	Goldy Najma Adli Kesaulya, et al. (2022)	<i>Transfer learning</i> dengan <i>pre-trained</i> model ResNeXt dengan melakukan <i>freezing</i> di 4 layer pertama dari 10 layer model <i>pre-trained</i>	Akurasi testing mencapai 98.19%
3	Deep Learning for Image Classification on Very Small	Menying Shu (2019)	<i>Fine-tuned pre-trained</i> model VGG16, VGG19, InceptionV3, InceptionResNetV2	Akurasi testing mencapai 96% dengan menggunakan <i>fine-tuned</i> model dari InceptionResNetV2

No	Judul	Penulis (Tahun)	Metode	Hasil
	Datasets Using Transfer Learning			
4	A Close Look at Deep Learning with Small Data	L Brigato, et al. (2020)	Review metode yang dapat digunakan untuk menyelesaikan permasalahan <i>small data</i> , menggunakan berbagai variasi dari model CNN dan ResNet	<i>Regularization technique</i> seperti <i>data augmentation</i> dan <i>dropout</i> dapat meningkatkan performa dari <i>deep learning</i>
5	A Comprehensive Study on Deep Image Classification with Small Datasets	Gayani Chandrarathne, et al. (2019)	Review metode <i>transfer learning</i> dengan <i>fine-tuned pre-trained</i> model VGG-16 pada berbagai macam dataset.	<i>Fine-tuning (re-init few layers)</i> dan (<i>whole network</i>) menunjukkan performa yang signifikan dibandingkan dengan <i>scratch training</i> . Hasil akurasi yang diperoleh dari <i>fine-tuning</i> adalah 91.4%, 95.52% dan 79.6% secara terurut
6	Understanding the Mechanisms of Deep Transfer Learning for Medical Images	Hariharan Ravishankar, et al. (2017)	CNN <i>transfer learning</i> CaffeNet	<i>Transferred</i> dan <i>fine-tuned</i> model dapat menungguli performa <i>state-of-the-art feature engineered pipeline</i> (Haar) dan menghasilkan akurasi 85%

No	Judul	Penulis (Tahun)	Metode	Hasil
7	Transfer Learning using CNN for Handwritten Devanagari Character Recognition	Nagender Aneja, et al. (2019)	<i>Transfer learning</i> AlexNet, DenseNet, VGG, dan Inception	InceptionV3 menghasilkan akurasi sebesar 99%
8	A Deep Learning-Based Framework for Automatic Brain Tumors Classification Using Transfer Learning	Arshia Rehman, et al. (2019)	<i>Transfer learning</i> menggunakan <i>pre-trained</i> model AlexNet, GoogLeNet, dan VGG16 dari dataset ImageNet	<i>Fine-tuned</i> VGG16 menghasilkan akurasi tertinggi sebesar 98.69%
9	A Review of Deep Transfer Learning and Recent Advancements	Mohammadreza Iman, et al. (2023)	Review berbagai metode <i>deep transfer learning</i> yang sudah diteliti dalam waktu dekat	(i) <i>Finetuning</i> , (ii) <i>Freezing CNN Layers</i> , dan (iii) <i>Progressive Learning</i> adalah teknik yang telah terbukti kemampuan dan efektivitasnya untuk berbagai masalah <i>machine learning</i> .
10	Text recognition on images using pre-trained CNN	Afgani Fajar Rizky, et al. (2023)	<i>Transfer leraning</i> dengan <i>augmentation</i> , <i>freeze-layers</i> , dan <i>fine-tuning</i> telah dilakukan dengan	Akurasi terbaik dihasilkan dari model VGG dengan 0 <i>freeze layer</i> dan <i>augmentation</i>


No	Judul	Penulis (Tahun)	Metode	Hasil
			menggunakan model AlexNet, VGG, ResNet, dan DenseNet	
11	Transfer learning using VGG-16 with Deep Convolutional Neural Network for Classifying Images	Srikanth Tammina (2019)	<i>Transfer learning</i> menggunakan <i>augmentation, fine-tuning, dan freeze layers</i> dengan <i>pre-trained</i> model VGG	Hasil terbaik diperoleh dari proses <i>fine-tuning</i> dan <i>augmentation</i> dengan akurasi 95.40% pada validation

BAB III

METODE PENELITIAN


3.1. Alur Penelitian

Penelitian akan dilakukan dengan bahasa pemrograman Python dan berbagai *library* yang disebutkan pada bab 3.3.2. Platform yang digunakan untuk mengimplementasikan penelitian adalah Kaggle Notebooks. Untuk mencapai tujuan yang telah dipaparkan pada bab I. Berikut flowchart penelitian yang dirancang untuk menjelaskan langkah - langkah yang akan diambil di penelitian ini, yang akan didetaillkan pada sub bab 3.2 dan seterusnya.

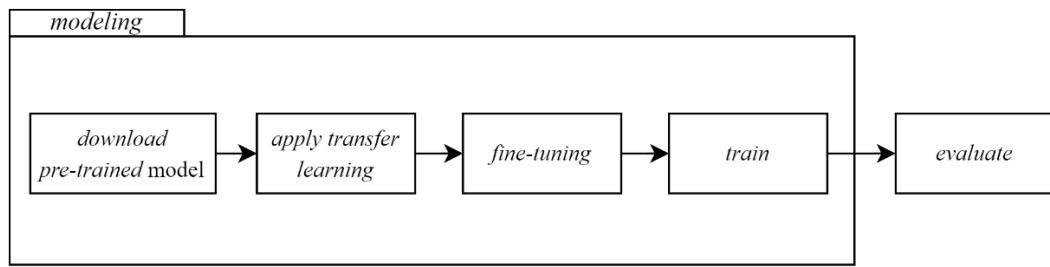


Gambar 3.1 Alur Penelitian

Secara garis besar, terdapat 4 tahap utama dari penelitian ini. Tahap pre-processing dan modeling akan diperjelas pada diagram flowchart dibawah ini.



Gambar 3.2 Alur Preprocessing



Gambar 3.3 Alur Modeling

Detail dari kedua diagram diatas akan dijelaskan lebih lanjut pada bab 3.3.3 dan seterusnya.

3.2. Data

Data yang penulis gunakan diambil dari kaggle. Kaggle adalah sebuah platform komunitas *data science* yang berisi berbagai sumber dataset, notebook, kompetisi, dan lain sebagainya. Terdapat tiga sumber dataset yang penulis ambil yaitu,

- a. <https://www.kaggle.com/datasets/phiard/aksara-jawa>
dengan total data 2634 sebagai sumber pertama
- b. <https://www.kaggle.com/datasets/vzrenggaman/hanacaraka>
dengan total data 1579 sebagai sumber kedua
- c. Pengumpulan dari 30 peserta berbeda dengan total data kurang lebih 800 data

Sumber data pertama dan kedua akan digabung menjadi satu sebagai dataset yang akan diuji oleh penulis. Total data yang akan digunakan di dalam penelitian ini adalah 4213 data. Kemudian, sumber data ketiga akan digunakan sebagai pengujian model terbaik dari hasil pelatihan.




Gambar 3.4 Data sumber pertama



Gambar 3.5 Data sumber kedua



Gambar 3.6 Data gabungan



Gambar 3.7 Data pengujian hasil pelatihan model

3.3. Alat dan Bahan

3.3.1. Spesifikasi Perangkat Keras

Perangkat yang digunakan pada penelitian ini diambil dari platform notebook kaggle. Kaggle menyediakan jupyter notebook yang bisa digunakan untuk menjalankan kode dengan menggunakan GPU, CPU, dan RAM yang cukup untuk mengimplementasikan *deep learning*. Berikut detail spesifikasinya:

- a. 20 GB of auto-saved disk space
- b. 1 Nvidia Tesla P100 GPU
- c. 2 CPU cores
- d. 13 Gigabytes of RAM

Lebih lengkapnya dapat dilihat di dokumentasi kaggle:

<https://www.kaggle.com/docs/notebooks>.

3.3.2. Libraries

Library yang akan digunakan pada penelitian ini mencakup visualisasi, *preprocessing*, *modeling*, dan evaluasi. Tensorflow, Albumentations, Numpy, Pandas, Matplotlib, Plotly, Sklearn akan digunakan di dalam penelitian ini.


3.3.3. Preprocessing

Dari data tersebut akan dilakukan *preprocessing* (lihat

Gambar 3.2 Alur Preprocessing) untuk mengoptimalkan pelatihan model yang digunakan nantinya. Pada penelitian ini, dilakukan berbagai skenario penelitian untuk melihat perbandingan hasil dari berbagai proses yang dilakukan. Pada bagian ini, augmentasi data akan dilakukan sesuai dengan skenario pengujian penulis.

3.3.3.1. Rescale/Resize


Dalam tahap ini citra akan melalui tahap *rescale* ke dalam ukuran 300 x 300. Hal ini dilakukan agar data yang akan digunakan untuk proses *training* seragam. Citra yang masuk ke dalam proses *training* juga diharuskan seragam, dalam data sebelumnya, beberapa citra mempunyai dimensi yang tidak sama dengan citra lainnya. Berikut adalah contoh rescale dari citra dimensi 364 x 300 menjadi 300 x 300.



Gambar 3.8 Contoh rescale

3.3.3.2. Normalisasi

Di tahap ini, penulis akan menggunakan teknik standardisasi pada citra. Hal ini dilakukan untuk mengoptimalkan dan menjaga kualitas data yang akan digunakan pada proses *training* nantinya. Berikut adalah contoh standardisasi data yang dilakukan dengan *library tensorflow*.




Gambar 3.9 Contoh standardisasi

3.3.3.3. Augmentasi

Dalam tahap ini, dilakukan augmentasi data dengan *config* seperti pada penelitian sebelumnya terkait data citra teks (Rizky et al., 2023). Berikut confignya:

- *Rotation: 15°*
- *Image Scale: 0.9*
- *Blur Effect*



Gambar 3.10 Contoh augmentasi

3.3.3.4. Data Splitting

Penulis akan melakukan tiga split menjadi *train*, *validation*, dan *test set* dari total data yang ada dengan perbandingan 0.9 : 0.05 : 0.05. Total data awal adalah 4242, hal ini akan menghasilkan *data split* sebesar 3817, 212, 212 secara terurut dari *train*, *validation*, dan *test set*.

3.3.4. Modeling


Tahap *modeling* (lihat **Gambar 3.3** Alur Modeling**Gambar 3.1** Alur Penelitian) akan dilakukan sesuai skenario pengujian yang tertera. Berikut detail dari tiap prosesnya.

3.3.4.1. Download Pre-trained Model

Semua pre-trained model ini akan diperoleh menggunakan *library* keras tensorflow. *Keras Applications* menyediakan berbagai *pre-trained* model yang dapat digunakan untuk penggunaan lebih lanjut seperti *prediction*, *feature extraction*, dan *fine-tuning*. Dokumentasi lebih lanjut dapat dilihat di <https://keras.io/api/applications/>. Model yang akan diunduh dari *keras application library* adalah VGG, Inception, dan Xception.

3.3.4.2. Apply Transfer Learning


Untuk melakukan transfer learning diperlukan kustomisasi pada layer yang diunduh dari *pre-trained* model keras *library*. Dalam beberapa penelitian sebelumnya, *transfer learning* dengan *pre-trained* model VGG dilakukan dengan menambahkan *fully connected layer* dan *output layer* dengan *activation function* softmax (Tammina, 2019).



Gambar 3.11 Contoh transfer learning


(Tammina, 2019)

Untuk menjaga kualitas model dan mencegah *overfitting*, digunakan juga *pooling layer* dan *dropout layer* pada lapisan *fully connected layer*. Ilustrasi dari kedua *layer* tersebut adalah sebagai berikut.



Gambar 3.12 Contoh pooling

sumber: https://www.researchgate.net/figure/The-difference-of-max-pooling-and-global-max-pooling_fig4_338079465



Gambar 3.13 Contoh dropout

(Zaccone & Karim, 2018)

3.3.4.3. Fine Tuning


Definisi dari *fine-tune* menurut *Oxford Languages* adalah membuat penyesuaian kecil (sesuatu) untuk mencapai yang terbaik atau kinerja yang diinginkan. Dalam konteks *deep transfer learning*, hal ini dapat dicapai dengan melakukan *freezing layer*, *train fully connected layer*, maupun *train all the network* (Iman et al., 2022). Pelaksanaan *fine-tuning* lebih detailnya dapat dilihat pada tabel skenario pengujian.

3.3.4.4. Train

Pada proses ini, dilakukan pelatihan model *transfer learning* dengan data yang sudah dilakukan *preprocessing*. Di dalam *training*, digunakan data *train* dan *validation* untuk mengukur nilai *overfitting* yang terjadi.

3.3.5. Evaluasi

Evaluasi akan dilakukan dengan metriks akurasi, sebagai tambahan digunakan juga *confusion matrix* untuk melihat kesalahan prediksi yang dilakukan oleh model yang sudah di-*train*. Berikut adalah contoh *confusion matrix* dengan 6 kelas prediksi. Dalam kasus penelitian ini, total kelas adalah 20, sehingga total baris dan kolom masing – masing adalah 20.



Gambar 3.14 Contoh confusion matrix

(Zaccone & Karim, 2018)

Percobaan model dengan data baru juga akan dilakukan untuk melihat kestabilan performa model (*generalization*). Rincian data dapat dilihat pada **Gambar 3.7** Data pengujian hasil pelatihan model atau bab IV, Percobaan Model dengan Data Baru.

3.4. Skenario Pengujian

Dalam tahap penelitian akan dilakukan evaluasi terhadap skenario pengujian dengan mengimplementasikan variabel augmentasi dan *freezing layer* dengan tiga model berbeda yaitu VGG, Inception, dan Xception. *Config* dari parameter augmentasi akan disesuaikan dengan penelitian terdahulu yang sudah disinggung pada bab 3.3.6. Skenario secara garis besar adalah seperti tabel berikut. Total pengujinya adalah 18.

Tabel 3.1 Skenario Pengujian

Model	Augmentasi	Freeze	Learning Rate	Layer	Optimizer
VGG	Yes, No	Full, $\frac{1}{2}$, None	0.001, 0.0001	1, 2	Adam, SGD
Inception	Yes, No	Full, $\frac{1}{2}$, None	0.001, 0.0001	1, 2	Adam, SGD
Xception	Yes, No	Full, $\frac{1}{2}$, None	0.001, 0.0001	1, 2	Adam, SGD


BAB IV

PENGUJIAN DAN ANALISIS

Bab ini membicarakan tentang tahap-tahap dalam proses pengenalan aksara Jawa dan hasil dari pengujian pengenalan aksara Jawa dengan menggunakan metode *Transfer Learning*.

4.1. Detail Skenario Pengujian

Skenario pengujian ini dilaksanakan dengan mengimplementasikan model VGG, Inception, dan Xception, masing-masing dengan parameter yang berbeda. Untuk memperjelas arsitektur model transfer learning yang digunakan, berikut adalah gambaran umum mengenai masing-masing model.



Gambar 4.1 Arsitektur Skenario

Ketiga model, yaitu VGG, Inception, dan Xception, memiliki kesamaan dalam tiga lapisan terakhirnya, yang mencakup proses pooling, pengaturan ulang klasifikasi (tuned classifier), dan lapisan softmax. Perbedaan utama antara model-model tersebut terletak pada bagian Feature Extractor (Ekstraktor Fitur), yang sesuai dengan arsitektur yang telah dijabarkan pada bab sebelumnya.

4.2. Parameter Pengujian

Penulis telah merinci sejumlah parameter yang akan diuji dalam penelitian ini, seperti yang tertera di **Tabel 3.1** Skenario Pengujian. Berdasarkan tabel tersebut, seluruh kombinasi yang ada telah diuji, menghasilkan total 144 skenario yang berbeda. Dalam proses pelatihan (*training*) masing-masing model, penulis juga telah mengimplementasikan *early stopping callback* yang berguna untuk mengehentikan pelatihan model (*training*) jika variabel yang dimonitor tidak mengalami peningkatan performa. Dalam kasus ini variabel tersebut adalah *validation loss*. Hal ini berguna untuk meminimalkan pemborosan sumber daya komputasi yang tidak perlu.

4.3. Matriks Kinerja

Hasil pengujian setiap skenario mencakup informasi tentang waktu pelatihan dan akurasi yang dihasilkan. Untuk menentukan model terbaik dari keseluruhan rangkaian pengujian, penentuan dilakukan berdasarkan akurasi pada set data uji (*test set*) tertinggi, serta waktu pelatihan terpendek yang dicapai.

4.4. Preprocessing Data

Tahap *preprocessing* pada data akan melalui berbagai proses yang telah disebutkan pada bab 3. Berikut adalah detail rinciannya.

4.4.1. Augmentasi

Pada keseluruhan data penulis akan melakukan augmentasi untuk menambah jumlah data yang dapat digunakan di penelitian ini.

Config atau pengaturan yang digunakan untuk melakukan augmentasi adalah rotasi, *scaling*, dan *blur*.

```

35  aug = Compose([
36      Rotate(limit=15, p=1),
37      RandomScale(scale_limit=0.7, p=1),
38      GaussianBlur(p=1)
39  ], p=1)

```

Gambar 4.2 Source code config augmentasi

Rinciannya terdapat pada gambar x, rotasi memiliki limit 15 yang berarti perubahan pada gambar baru akan mengalami rotasi sebanyak $-15 - 15$ derajat. *Random scale* mempunyai limit sebanyak 0.7, hal ini berarti gambar *source* akan mengalami penurunan kualitas dalam range $0.7 - 1$. *Gaussian blur* mempunyai blur limit default sebanyak (3, 7) detail dari hal tersebut dapat dilihat pada sumber referensi *library* albumentations (Buslaev dkk., 2020). Variabel p mengindikasikan probabilitas *config* tersebut dapat tereksekusi. Jika nilai p=1 hal ini berarti *config* tersebut akan selalu dijalankan.

```

5 # do augmentation 5 times with 1 image
6 repeat = 5
7
8 # loop through base folder → splitted data folder → class folder → img
9 def augment_and_save_images(aug, input_folder, output_folder):
10    for split_folder in os.listdir(input_folder):
11        split_input_folder = os.path.join(input_folder, split_folder)
12        split_output_folder = os.path.join(output_folder, split_folder)
13        os.makedirs(split_output_folder, exist_ok=True)
14
15    for class_folder in os.listdir(split_input_folder):
16        class_input_folder = os.path.join(split_input_folder, class_folder)
17        class_output_folder = os.path.join(split_output_folder, class_folder)
18        os.makedirs(class_output_folder, exist_ok=True)
19
20    for image_name in os.listdir(class_input_folder):
21        image_path = os.path.join(class_input_folder, image_name)
22        img = cv2.imread(image_path)
23        data = {'image': img}
24        img_base, ext = os.path.splitext(image_name)
25
26        # check progress
27        print(class_input_folder + '/' + image_name)
28
29        for i in range(repeat):
30            aug_data = aug(**data)
31            augmented_image = aug_data['image']
32            output_path = os.path.join(class_output_folder, img_base + f'{i}' + ext)
33            cv2.imwrite(output_path, augmented_image)
34

```

Gambar 4.3 *Source code* fungsi augmentasi

Gambar 4.3 *Source code* fungsi augmentasi merupakan fungsi yang digunakan untuk melakukan augmentasi. Fungsi tersebut mempunyai 3 parameter yang mengandung informasi terkait config augmentasi, input folder, dan output folder. Di dalam fungsi ini, setiap satu gambar source akan diaugmentasi sebanyak 5 gambar berbeda. Hasil dari tiap gambar akan berbeda dikarenakan augmentasi dilakukan secara random berdasarkan limit yang telah ditentukan masing – masing config. Total sumber data yang telah dibersihkan adalah 3876 gambar dan setelah diaugmentasi, total data menjadi 19128 gambar.

4.4.2. Preprocessing Pipeline

Proses preprocessing data selanjutnya akan dilakukan didalam sebuah fungsi pipeline. Berikut adalah cuplikan dari source code-nya.

```
1 def load_and_preprocess_image(image, label):
2     # Resize the image to the desired size
3     image = tf.image.resize(image, [IMAGE_SIZE, IMAGE_SIZE])
4
5     # Rescale pixel values to be in the range [0, 1]
6     image = tf.image.per_image_standardization(image)
7
8     return image, label
```

Gambar 4.4 *Source code fungsi preprocessing pipeline*

Hal yang dilakukan berdasarkan **Gambar 4.4** *Source code fungsi preprocessing pipeline* adalah *resizing* dan standarisasi gambar. Dalam implementasi ini, variabel IMAGE_SIZE adalah 300, yang berarti setiap gambar akan di-*resize* ke dalam dimensi 300 x 300 pixel.

4.5. Modelling

4.5.1. Pembuatan Model

Proses pembuatan model yang pertama kali adalah melakukan download *pre-trained* model yang dibutuhkan. Dengan *library* TensorFlow, hal ini dapat dilakukan dengan menulis kode saja, berikut adalah rinciannya.

```
# Download Xception

xception_no_train = Xception(input_shape=(IMAGE_SIZE, IMAGE_SIZE, 3), weights='imagenet', include_top=False)
xception_no_train.trainable = False

xception_half_train = Xception(input_shape=(IMAGE_SIZE, IMAGE_SIZE, 3), weights='imagenet', include_top=False)
xception_half_train.trainable = True

xception_full_train = Xception(input_shape=(IMAGE_SIZE, IMAGE_SIZE, 3), weights='imagenet', include_top=False)
xception_full_train.trainable = True
```

Gambar 4.5 *Source code download pre-trained model Xception*

Gambar 4.5 *Source code download pre-trained model Xception* menunjukkan source code yang diperlukan untuk mengunduh 3 model yang sama. Masing – masing model ini nantinya akan dirubah untuk dapat mengimplementasikan freeze layer yang sudah disebutkan pada bab 3. Pada model pertama, dilakukan inisialisasi trainable = False, ini berarti model tidak akan mengalami pelatihan ulang pada layer feature extractor. Sebaliknya untuk nilai True, model tersebut akan melalui proses pelatihan ulang bagian layer feature extractor.

Model – model tersebut akan ditambahkan layer yang lain (Pooling, Tuned Classifier, dan Softmax) untuk membuat arsitektur seperti yang telah disebutkan pada skenario simulasi.

```
Model: "aksara_jawa_xception_full_freeze_v1"
-----
Layer (type)          Output Shape         Param #
=====
xception (Functional) (None, 10, 10, 2048) 20861480
global_average_pooling2d (G (None, 2048)      0
lobalAveragePooling2D)
dropout (Dropout)     (None, 2048)          0
dense (Dense)         (None, 1024)          2098176
dropout_1 (Dropout)   (None, 1024)          0
dense_1 (Dense)       (None, 20)             20500
=====
Total params: 22,980,156
Trainable params: 2,118,676
Non-trainable params: 20,861,480
-----
```

Gambar 4.6 *Summary Model Xception Full Freeze*

Gambar 4.6 adalah salah satu contoh model dengan 2 tuned classifier. Model ini mengimplementasikan full freeze dengan feature extractor model Xception.

4.5.2. Pelatihan Model

Model – model yang telah dibuat sebelumnya, akan dilatih dengan maksimum epoch sebanyak 50. Berikut merupakan cuplikan kode untuk melatih model.

```

print(f"\nTraining {xception_transferred_full.name}: ")

csv_file = f'{xception_transferred_full.name}.csv'

time = timer(None)
history_full = xception_transferred_full.fit(
    train_ds_mapped,
    validation_data=val_ds_mapped,
    epochs=EPOCHS,
    callbacks=[
        EarlyStopping(patience=EARLYSTOP_PATIENCE, restore_best_weights=True),
        ModelCheckpoint(f"checkpoint-{xception_transferred_full.name}.h5", save_best_only=True),
        CSVLogger(csv_file)
    ],
    batch_size=BATCH_SIZE,
)
time_taken = timer(time)
print(time_taken)

Training aksara_jawa_xception_full_freeze_v1:
Epoch 1/50
532/532 [=====] - 97s 163ms/step - loss: 2.2114 - accuracy: 0.3692 - val_loss: 1.4435 - val_accuracy: 0.6551
Epoch 2/50
532/532 [=====] - 84s 158ms/step - loss: 1.4340 - accuracy: 0.5820 - val_loss: 1.0445 - val_accuracy: 0.7459
Epoch 3/50
532/532 [=====] - 84s 157ms/step - loss: 1.1733 - accuracy: 0.6459 - val_loss: 0.8696 - val_accuracy: 0.7836

Epoch 49/50
532/532 [=====] - 85s 158ms/step - loss: 0.3764 - accuracy: 0.8761 - val_loss: 0.3184 - val_accuracy: 0.9034
Epoch 50/50
532/532 [=====] - 85s 158ms/step - loss: 0.3723 - accuracy: 0.8750 - val_loss: 0.3254 - val_accuracy: 0.9072
1 hours 30 minutes and 9.83 seconds.

```

Gambar 4.7 Source code beserta output pelatihan tiap epoch

Berdasarkan pada **Gambar 4.7**, pada setiap epoch, nilai accuracy, loss, validation accuracy, dan validation loss akan disimpan ke dalam sebuah csv yang nantinya akan digunakan untuk

menganalisis performa model berdasarkan epoch yang telah dilalui.

Proses pelatihan juga menggunakan ModelCheckpoint untuk menyimpan model dalam setiap epoch-nya, untuk menghindari hilangnya model jika terjadi crash. Waktu pelatihan model juga akan dihitung dengan fungsi timer yang telah dibuat penulis sebagai evaluasi performa model.

4.6. Analisis Hasil Pengujian

Pelatihan setiap model telah terekam dan akan dianalisis dalam bentuk tabel seperti yang terlampir di bawah ini:


Tabel 4.1 Hasil Pelatihan Model berdasarkan Skenario Pengujian

141	Xception	No	None	0.001	2	Adam	0.99	1.00	0.98	0.13	15	14
142	Xception	No	Full	0.0001	2	Adam	0.80	0.82	0.75	0.87	16	50
143	Xception	No	$\frac{1}{2}$	0.0001	2	Adam	1.00	0.97	0.93	0.21	8	14
144	Xception	No	None	0.0001	2	Adam	1.00	1.00	0.98	0.04	14	15

Untuk memfasilitasi analisis, penulis menggunakan berbagai grafik seperti line dan bar chart. Analisis dilakukan secara komprehensif, meliputi ruang lingkup model serta dampak dari masing-masing parameter yang digunakan.


4.6.1. Evaluasi Matriks Kinerja

Test by __index__




Gambar 4.8 Hasil keseluruhan skenario pengujian berdasarkan nilai akurasi test

Gambar 4.8 menggambarkan visualisasi dari seluruh skenario yang telah diuji. Plotting dilakukan dengan nilai indeks pada tabel sebagai sumbu x (x-axis) dan akurasi uji (test accuracy) sebagai sumbu y (y-axis). Hasil plot menunjukkan bahwa beberapa model VGG menghasilkan akurasi uji yang stagnan, hanya mencapai sekitar 5% pada beberapa indeks. Penelitian mendalam menunjukkan bahwa model tersebut tidak mengalami peningkatan performa seiring berjalannya setiap epoch. Berdasarkan grafik x terlihat hasil dari pelatihan (training) salah satu model VGG tersebut.




Gambar 4.9 Grafik Pelatihan Model VGG dengan stagnansi (*loss*)




Gambar 4.10 Grafik Pelatihan Model VGG dengan stagnansi (*accuracy*)

Pada **Gambar 4.9** dan **Gambar 4.9**, terjadi stagnansi pada validation accuracy dna validation loss. Stagnansi pada pelatihan ini dapat disebabkan oleh ketidakcocokan parameter, dataset, atau arsitektur model yang digunakan dengan konteks penelitian ini (klasifikasi citra huruf tulis tangan aksara Jawa). Hasil skenario juga menunjukkan bahwa penggunaan optimizer Adam pada model VGG berpotensi menghasilkan stagnansi dalam pelatihan.




Gambar 4.11 *Bar-chart* rerata akurasi tiap jenis model

Dari **Gambar 4.11**, dapat disimpulkan bahwa model VGG memiliki rata-rata akurasi terendah dibandingkan dengan model Inception dan Xception. Namun, perlu diingat bahwa hasil tersebut bisa saja terpengaruh oleh beberapa model yang mengalami stagnansi dalam pelatihan sehingga grafik yang tertera menjadi bias. Grafik di bawah menunjukkan jumlah model dari masing-masing tipe model yang berhasil mencapai akurasi uji di atas 50%.




Gambar 4.12 Bar-chart rerata akurasi tiap jenis model dengan filter




Gambar 4.13 Bar-chart jumlah model terfilter

Berdasarkan grafik tersebut, terlihat bahwa performa model VGG tidak kalah dengan model Inception dan Xception. Namun, jumlah model yang berhasil mencapai kategori akurasi uji di atas 50% lebih banyak pada model Inception, yakni sebanyak 40 model.



Gambar 4.14 Bar-chart waktu pelatihan tiap model



Gambar 4.15 Bar-chart rerata waktu pelatihan tiap jenis model

Gambar 4.14 menunjukkan waktu yang diperlukan oleh seluruh model untuk menyelesaikan pelatihan mereka. Sementara itu, **Gambar 4.15** menggambarkan rata-rata waktu pelatihan dari masing-masing model. Berdasarkan informasi tersebut, dapat disimpulkan

bahwa secara umum, model Inception memiliki waktu pelatihan tercepat dibandingkan dengan model VGG dan Xception. Berikut adalah beberapa contoh hasil uji skenario yang diurutkan berdasarkan kolom Time secara menaik (*ascending*):

Tabel 4.2 Hasil uji skenario tiap model diurutkan berdasarkan kolom Time


Id	Model	Augmentasi	Freeze	Learning Rate	Layer	Optimizer	Result Train	Validation	Test	Test Loss	Time (min)	Epoch
95	Inception	No	$\frac{1}{2}$	0.0001	2	Adam	1.00	0.98	0.95	0.17	3	11
86	Inception	No	$\frac{1}{2}$	0.001	1	Adam	0.99	0.99	0.99	0.05	3	11
44	VGG	No	$\frac{1}{2}$	0.001	2	Adam	0.05	0.05	0.05	3.00	4	8
139	Xception	No	Full	0.001	2	Adam	0.75	0.79	0.74	0.91	5	15
134	Xception	No	$\frac{1}{2}$	0.001	1	Adam	0.98	0.99	0.93	0.16	5	9
...

Hasil **Tabel 4.2** menunjukkan bahwa Inception adalah model yang paling cepat menyelesaikan proses pelatihan hanya dalam 11 *epoch* dengan total waktu pelatihan selama 3 menit.

4.6.2. Evaluasi Parameter terhadap Matriks Kinerja


Dalam bagian ini, penulis akan menguraikan parameter-parameter yang digunakan serta dampak masing-masing parameter tersebut pada performa model, terutama dari segi waktu pelatihan dan akurasi set uji (*test set*).

Augmentasi terhadap Akurasi Test




Gambar 4.16 Bar-chart performa akurasi berdasarkan parameter augmentasi

Augmentasi terhadap Training Time




Gambar 4.17 Bar-chart performa waktu berdasarkan parameter augmentasi

Berdasar pada **Gambar 4.16** dan **Gambar 4.17**, parameter augmentasi ini memiliki dampak yang signifikan pada akurasi uji dan waktu pelatihan. Ketika augmentasi diterapkan, dampak terhadap waktu pelatihan menjadi lebih besar. Hal ini dapat dibuktikan dari grafik ... terjadi perbedaan signifikan antara nilai parameter “Yes” dan “No”. Dalam kasus ini, Xception mengalami perbedaan waktu pelatihan paling banyak.




Gambar 4.18 Bar-chart performa akurasi berdasarkan parameter *freeze*




Gambar 4.19 Bar-chart performa waktu berdasarkan parameter *freeze*

Berdasar pada **Gambar 4.18** dan **Gambar 4.19**, parameter *freeze* dengan nilai ‘None’ menunjukkan dampak yang paling signifikan terhadap akurasi uji pada model Inception dan Xception. Sebaliknya, model VGG mencapai akurasi tertinggi ketika parameter *freeze* diatur ke ‘Full’. Selain itu, parameter ini juga memiliki pengaruh signifikan terhadap durasi pelatihan model. Nilai ‘None’ menghasilkan durasi pelatihan yang paling lama, sementara nilai ‘½’ menghasilkan durasi pelatihan terpendek. Nilai ‘Full’ berada di antara keduanya. Durasi pelatihan yang lebih lama untuk nilai ‘None’ dapat dijelaskan oleh fakta bahwa model perlu melatih ulang semua *weight* dan *bias* dari setiap *layer* model.




Gambar 4.20 Bar-chart performa akurasi berdasarkan parameter *learning rate*




Gambar 4.21 Bar-chart performa waktu berdasarkan parameter *learning rate*

Berdasar pada **Gambar 4.20** dan **Gambar 4.21**, parameter *learning rate* dengan nilai 0.001 menghasilkan akurasi yang lebih tinggi dibandingkan dengan nilai 0.0001. Namun, efek ini hanya berlaku untuk model Inception dan Xception, sementara VGG tidak mengalami perubahan yang signifikan dalam perbedaan nilai parameter ini. Hasil grafik menunjukkan bahwa perbedaan performa akurasi set uji hanya berbanding 1%. Terkait waktu pelatihan model, nilai learning rate 0.0001 menghasilkan waktu pelatihan yang lebih lama. Hal ini dikarenakan semakin kecil nilai *learning rate*, semakin lama pula proses konvergensi terjadi dalam tahap pelatihan model.




Gambar 4.22 Bar-chart performa akurasi berdasarkan parameter *layer*



Gambar 4.23 Bar-chart performa waktu berdasarkan parameter *layer*


Berdasar pada **Gambar 4.22** dan **Gambar 4.23**, parameter *layer* tidak memberikan dampak yang signifikan pada akurasi uji maupun waktu pelatihan model untuk ketiga model tersebut.

Optimizer terhadap Akurasi Test




Gambar 4.24 Bar-chart performa akurasi berdasarkan parameter *optimizer*

Optimizer terhadap Training Time



Gambar 4.25 Bar-chart performa waktu berdasarkan parameter *optimizer*

Berdasar pada **Gambar 4.24** dan **Gambar 4.25**, parameter *optimizer* ini memiliki dampak signifikan pada akurasi uji dan waktu pelatihan model. Terdapat perbedaan antara model VGG dan dua model lainnya (Inception dan Xception). Model VGG mencapai hasil akurasi uji yang lebih baik dengan nilai parameter SGD dibandingkan dengan Adam. Sedangkan pada kedua model lainnya, Adam menghasilkan akurasi uji yang lebih baik. Selain itu, waktu pelatihan untuk nilai parameter SGD pada umumnya membutuhkan lebih banyak waktu dibandingkan dengan parameter Adam. Model Xception mengalami perbandingan tertinggi untuk waktu pelatihan model. Lama waktu pelatihan dengan nilai SGD hampir mencapai 3x waktu pelatihan dengan nilai parameter Adam.



Gambar 4.26 Correlation matrix dari data hasil uji skenario

Didukung oleh matriks korelasi (correlation matrix) pada

Gambar 4.26, temuan-temuan yang telah disebutkan sebelumnya menguatkan kesimpulan tersebut, membuktikan hubungan antara parameter-parameter tersebut dengan performa model. Sebagai salah satu contoh, variabel ‘Augmentasi_Yes’ dan ‘Time (min)’ mempunyai nilai korelasi positif yang paling tinggi, yaitu sebesar 0,61. Artinya,

penggunaan nilai “Yes” pada parameter Augmentasi akan memberikan dampak positif terhadap variabel Time (min). Dengan kata lain, waktu yang dibutuhkan untuk melatih model akan menjadi lebih panjang. Hal ini dapat diulas kembali pada gambar **Gambar 4.17** yang menunjukkan bahwa nilai perbandingan terbesar waktu pelatihan terletak pada parameter Augmentasi.

4.6.3. Evaluasi Top 10 Models

Pada bagian ini, penulis akan mengulas 10 model terbaik untuk setiap jenis model berdasarkan akurasi uji (*test set*) mereka. Dengan adanya 3 jenis model yang berbeda, total model yang akan dievaluasi adalah 30 model yang berbeda. Tujuan dari analisis ini adalah untuk mendalami parameter-parameter yang paling berpengaruh dalam menciptakan model terbaik. Penulis akan menganalisis parameter-parameter yang dominan digunakan dalam total 30 model terbaik ini.

Di bawah ini adalah daftar model yang masuk dalam kategori 10 model terbaik pada masing – masing jenis model.


Tabel 4.3 Hasil uji skenario 10 model terbaik

Id	Model	Augmentasi	Freeze	Learning Rate	Layer	Optimizer	Result Train	Validation	Test	Test Loss	Time (min)	Epoch
65	Inception	Yes	None	0.0001	1	Adam	0.9982	0.9961	1	0.002035	38	14
89	Inception	No	None	0.0001	1	Adam	0.9991	0.9952	1	0.004126	11	19
62	Inception	Yes	None	0.001	1	Adam	0.9956	1	0.996	0.00795	74	27
68	Inception	Yes	None	0.001	2	Adam	0.9949	0.9942	0.996	0.009453	52	19

50	Inception	Yes	None	0.001	1	SGD	0.999	0.9903	0.9921	0.02624	65	23
56	Inception	Yes	None	0.001	2	SGD	0.9996	0.9961	0.9901	0.03117	79	31
74	Inception	No	None	0.001	1	SGD	0.9988	0.9952	0.9901	0.05131	28	50
86	Inception	No	None	0.001	1	Adam	0.9882	0.9952	0.9901	0.04759	9	16
91	Inception	No	$\frac{1}{2}$	0.001	2	Adam	0.9962	0.9903	0.9901	0.03443	5	17
95	Inception	No	None	0.0001	2	Adam	0.9941	1	0.9901	0.03589	8	14
25	VGG	No	$\frac{1}{2}$	0.001	1	SGD	0.9838	0.9903	0.995	0.1023	22	44
40	VGG	No	$\frac{1}{2}$	0.0001	1	Adam	0.9971	1	0.995	0.01521	18	35
1	VGG	Yes	$\frac{1}{2}$	0.001	1	SGD	0.9952	0.9942	0.9921	0.04196	62	30
2	VGG	Yes	None	0.001	1	SGD	0.9871	0.9913	0.9921	0.02506	50	13
31	VGG	No	$\frac{1}{2}$	0.001	2	SGD	0.9471	0.9855	0.9901	0.0664	19	39
46	VGG	No	$\frac{1}{2}$	0.0001	2	Adam	0.9927	0.9952	0.9901	0.02785	24	50
11	VGG	Yes	None	0.0001	2	SGD	0.9454	0.9826	0.9881	0.04981	185	50
23	VGG	Yes	None	0.0001	2	Adam	0.9931	0.9961	0.9851	0.07386	66	19
26	VGG	No	None	0.001	1	SGD	0.9888	0.9807	0.9851	0.1034	26	28
7	VGG	Yes	$\frac{1}{2}$	0.001	2	SGD	0.9918	0.9932	0.9842	0.06673	59	28
134	Xception	No	None	0.001	1	Adam	0.9815	0.9855	1	0.01162	10	9
113	Xception	Yes	None	0.0001	1	Adam	0.9992	0.9981	0.997	0.01017	45	10
104	Xception	Yes	None	0.001	2	SGD	0.9991	0.9865	0.996	0.0247	221	50
116	Xception	Yes	None	0.001	2	Adam	0.9912	0.9971	0.9931	0.02588	44	10
119	Xception	Yes	None	0.0001	2	Adam	0.999	1	0.9921	0.0427	83	19
98	Xception	Yes	None	0.001	1	SGD	0.9994	0.9894	0.9911	0.03065	220	50
115	Xception	Yes	$\frac{1}{2}$	0.001	2	Adam	0.9949	0.9981	0.9911	0.02447	37	13


137	Xception	No	None	0.0001	1	Adam	0.9982	0.9903	0.9901	0.02281	11	11
110	Xception	Yes	None	0.001	1	Adam	0.9949	0.9971	0.9881	0.0348	52	12
109	Xception	Yes	$\frac{1}{2}$	0.001	1	Adam	0.992	0.9971	0.9871	0.041	23	8

Digambarkan secara *bar-chart*, berikut adalah performa masing – masing 10 model terbaik dalam nilai akurasi set uji (*test set*).




Gambar 4.27 *Bar-chart* performa akurasi set uji 10 model terbaik

Berikut adalah analisis dampak masing – masing parameter terhadap waktu pelatihan model dan hasil akurasi set uji (*test set*) untuk top 10 models.




Gambar 4.28 Bar-chart jumlah model berdasarkan parameter augmentasi

Gambar 4.28 menggambarkan hasil 10 model terbaik untuk masing-masing jenis model beserta parameter augmentasi (Yes/No). Dapat diperhatikan bahwa 8 dari 10 model terbaik Xception menggunakan augmentasi. Untuk kedua model lainnya (VGG dan Inception), nilai parameter (Yes/No) diambil dengan rasio yang sama.




Gambar 4.29 Bar-chart jumlah model berdasarkan parameter *freeze*

Dari Gambar 4.29, tidak ada model yang menggunakan nilai "Full" untuk parameter ini. Mayoritas model terbaik menggunakan nilai " $\frac{1}{2}$ " atau "None". Model terbaik Inception dan Xception rata-rata menggunakan nilai parameter "None", sementara model VGG lebih banyak menggunakan nilai " $\frac{1}{2}$." Hal ini menunjukkan bahwa *transfer learning* dengan model yang telah dilatih dari data ImageNet tidak selalu sesuai dengan tugas klasifikasi citra huruf tulisan tangan aksara Jawa. Salah satu alasannya adalah fitur-fitur yang diperoleh dari pelatihan dengan dataset citra ImageNet berbeda dengan citra tulisan tangan aksara Jawa.




Gambar 4.30 Bar-chart jumlah model berdasarkan parameter *learning rate*

Berdasarkan informasi **Gambar 4.30**, parameter *learning rate* dengan nilai 0.001 dominan digunakan dalam masing – masing 10 model terbaik.




Gambar 4.31 Bar-chart jumlah model berdasarkan parameter *layer*

Berdasarkan **Gambar 4.31**, rata – rata dari 10 model terbaik ini, dihasilkan dengan nilai *layer* 1, terutama untuk model Inception dan Xception. Untuk model VGG, masing – masing nilai *layer* (1 atau 2) memiliki jumlah count yang sama. Dengan kata lain, parameter ini tidak terlalu berdampak terhadap performa untuk model VGG.




Gambar 4.32 Bar-chart jumlah model berdasarkan parameter *optimizer*


Sama seperti evulasi parameter keseluruhan model, *top 10 models* Inception dan Xception cenderung lebih cocok dengan nilai parameter *optimizer* Adam. Sedangkan rata – rata model VGG lebih cocok menggunakan *optimizer* SGD. Hal ini dapat diamati dari jumlah hitungan (*count*) masing-masing nilai parameter *optimizer* yang menunjukkan dominasi dibandingkan dengan nilai-nilai lainnya. Ini menunjukkan bahwa pemilihan *optimizer* memiliki peran penting dalam peningkatan performa model dan dapat berbeda-beda tergantung pada jenis model yang digunakan.




Gambar 4.33 Grafik akurasi pelatihan 10 model terbaik



Grafik dari **Gambar 4.33** dan **Gambar 4.34** merupakan hasil akurasi *training* dan *validation* untuk 10 model terbaik berdasarkan tiap epochnya. Dari grafik tersebut, tidak semua model menjalani proses *training* hingga 50 epoch.



Gambar 4.35 Grafik *loss* pelatihan 10 model terbaik




Gambar 4.36 Grafik *validation loss* pelatihan 10 model terbaik

Grafik yang digambarkan di atas (**Gambar 4.33**, **Gambar 4.34**, **Gambar 4.35**, **Gambar 4.36**) mewakili nilai akurasi dan *loss* dari proses pelatihan dan validasi dari masing-masing *top 10 models*. Terlihat jelas bahwa semua model terbaik telah mampu “belajar” secara efektif dari dataset yang digunakan untuk pelatihan. Hal ini dapat disimpulkan dari keseluruhan grafik tersebut, yang secara umum

menunjukkan bahwa setiap model telah mengalami konvergensi, dengan peningkatan akurasi yang bertahap dan penurunan *loss* yang landai walaupun terjadi fluktuasi dalam akurasi validasi dan *loss* dalam epoch 1 – 25.


Count of epoch by source




Gambar 4.37 Bar-chart epoch masing – masing 10 model terbaik

Grafik di atas mewakili jumlah *epoch* yang dilakukan dalam proses pelatihan masing-masing *top 10 models*. Berdasarkan gambar tersebut, hanya lima model yang mencapai 50 *epoch*. Setiap model memiliki rata-rata *epoch* yang berbeda, menunjukkan kapabilitas masing-masing model dalam proses pelatihan. Sebagai contoh, model Xception sebagian besar hanya membutuhkan kurang dari 20 epoch untuk mencapai kinerja maksimal yang dapat diukur dari pengujian


dengan dataset validasi. Namun, kapabilitas masing-masing model dalam pelatihan tidak selalu menentukan kinerja akhir model. Hal ini akan dibahas lebih lanjut pada bab 4.7, yang akan meninjau kinerja model dengan membuat prediksi dari data di luar sumber pelatihan model (pelatihan, validasi, uji).




Gambar 4.38 Grafik rerata akurasi 10 model terbaik tiap *epoch*



Gambar 4.39 Grafik rerata akurasi validasi 10 model terbaik tiap *epoch*




Gambar 4.40 Grafik rerata *loss* 10 model terbaik tiap *epoch*




Gambar 4.41 Grafik rerata *validation loss* 10 model terbaik tiap *epoch*

Grafik di atas menggambarkan rata-rata akurasi dan loss pada pelatihan dan validasi per *epoch*, yang dikelompokkan berdasarkan model. Pengamatan signifikan dari gambar ini terkait


dengan model VGG. Model ini menunjukkan konvergensi yang lebih lambat dibandingkan dengan dua model lainnya (Inception dan Xception). Namun, pada akhirnya, model tersebut masih berhasil mencapai kinerja yang setara dengan model Inception dan Xception.




Gambar 4.42 Grafik rerata akurasi validasi 10 model terbaik tiap *epoch* berdasarkan nilai parameter augmentasi




Gambar 4.43 Grafik rerata akurasi validasi 10 model terbaik tiap *epoch* berdasar nilai parameter *freeze*



Gambar 4.44 Grafik rerata akurasi validasi 10 model terbaik tiap *epoch* berdasar nilai parameter *learning rate*



Gambar 4.45 Grafik rerata akurasi validasi 10 model terbaik tiap *epoch* berdasar nilai parameter *layer*



Gambar 4.46 Grafik rerata akurasi validasi 10 model terbaik tiap *epoch* berdasar nilai parameter *optimizer*

Grafik di atas (**Gambar 4.42****Gambar 4.43****Gambar 4.44****Gambar 4.45****Gambar 4.46**) mewakili dampak masing-masing parameter terhadap akurasi validasi selama *epoch* pelatihannya. Dampak yang dihasilkan dengan nilai yang berbeda dari masing-masing parameter hanya mempengaruhi proses pelatihan model di *epoch* 1 – 25. Setelah itu, kinerja yang dihasilkan oleh masing-masing model di *epoch* akhir adalah sama.

Penggunaan augmentasi mempercepat konvergensi di awal proses pelatihan model. Hal ini karena dataset yang digunakan untuk pelatihan di setiap *epoch* lebih besar dibandingkan dengan dataset yang tidak diaugmentasi. Nilai “½” pada *freeze* menunjukkan proses konvergensi yang lebih lambat dibandingkan dengan nilai “None”. Hal

ini karena proses pembaruan bobot dalam model dilakukan secara menyeluruh untuk nilai “None” dan hanya setengah untuk nilai “½”.

Learning rate 0.001 menunjukkan konvergensi yang lebih cepat. Hal ini umum, karena semakin kecil *learning rate*, semakin lama konvergensi terjadi dalam proses pelatihan model. *Layer* dengan nilai 1 menunjukkan konvergensi yang lebih cepat. Hal ini bergantung pada arsitektur model. Karena ada lebih banyak *layer dropout* pada parameter *layer* dengan nilai 2, hal ini mungkin terjadi. *Optimizer* SGD menunjukkan konvergensi yang lebih lambat pada tahap awal pelatihan model. Namun, di sisi lain, Adam mengalami fluktuasi dan penurunan kinerja pada *epoch* 10 – 20.

Analisis ini memberikan wawasan berharga tentang perilaku berbagai model di bawah berbagai parameter selama proses pelatihan. Penting untuk dicatat bahwa meskipun parameter tertentu dapat mempercepat proses konvergensi, hal tersebut mungkin tidak selalu mengarah ke kinerja yang lebih baik di *epoch* akhir. Oleh karena itu, pertimbangan dan penyetelan yang hati-hati terhadap tiap parameter sangat penting dalam mencapai kinerja model yang optimal.

4.7. Percobaan Model dengan Data Baru


Pada bagian ini, beberapa model yang telah dibuat akan diuji performanya berdasarkan data baru di luar dataset yang digunakan dalam proses pelatihan model. Dengan uji coba ini, penulis berharap untuk memahami sejauh mana model yang telah dilatih dapat menangani data baru yang memiliki karakteristik yang berbeda. Hasilnya diharapkan dapat memberikan wawasan yang berharga dalam mengevaluasi performa model pada aplikasi dunia nyata.

Data baru ini diperoleh melalui tulisan tangan di atas kertas hvs menggunakan bolpoin, kemudian dipindai menggunakan printer, dan dipotong menggunakan perangkat lunak Adobe Photoshop untuk mengambil setiap huruf dari tulisan tangan. Data ini diperoleh dari 30 individu yang memiliki berbagai tingkat pengalaman dalam menulis aksara Jawa. Proses pembersihan data juga dilakukan oleh penulis untuk menghapus data yang tidak sesuai dengan tulisan aksara Jawa.

4.7.1. Parameter Pengambilan Model

Dalam uji coba ini, *top 10 models* yang telah dianalisis sebelumnya akan digunakan, ditambah dengan *top 3 models* lainnya berdasarkan parameter *freeze*. Pengambilan *top 3 models* ini bertujuan untuk memahami sejauh mana *transfer learning* dapat diimplementasikan dalam kasus ini. Berikut adalah grafik yang menunjukkan hasil akurasi uji pada *top 3 models* tersebut.

Test by __index__




Gambar 4.47 Bar-chart 3 model terbaik berdasarkan nilai tiap parameter *freeze*

Semua model dengan nilai “Full” pada parameter *freeze* tidak terlihat pada *top 10 models*. Namun, kinerja model dengan nilai parameter tersebut tidak terlalu buruk. Untuk model VGG, bisa mencapai akurasi 90%. Hal ini layak ditelusuri lebih lanjut terkait pengujian kinerja model dengan data baru.

4.7.2. Data


Berikut adalah contoh data sampel baru yang akan digunakan untuk memprediksi citra huruf aksara Jawa. Data ini berbeda dari data yang digunakan selama pelatihan model karena merupakan hasil tulisan tangan di atas kertas. Sedangkan data pelatihan adalah citra tulisan tangan digital. Dengan uji coba ini, penulis bertujuan untuk mengevaluasi kemampuan kinerja model yang telah dilatih. Detail dari data adalah sebagai berikut.

- Data yang telah di-scan




Gambar 4.48 Data Aksara Jawa setelah di-scan dari kertas

- Data yang telah di-*crop*




Gambar 4.49 Data Aksara Jawa setelah di-*crop* menggunakan perangkat lunak

- Data yang sudah melalui tahap *preprocessing*



Gambar 4.50 Data Aksara Jawa setelah dilakukan *preprocessing*

- Beberapa contoh data yang dibuang (*cleaning*)



Gambar 4.51 Data Aksara Jawa yang dihapus (*cleaning*)

4.7.3. Hasil

Pengujian ini dilakukan menggunakan dua pendekatan, yaitu menggunakan *top 10 models* yang telah diidentifikasi sebelumnya dan dengan menggunakan *top 3 models* berdasarkan nilai parameter *freeze*.

Berikut adalah rincian hasilnya dalam format tabel.

4.7.3.1. Menggunakan top 10 models

Tabel 4.4 Rincian hasil percobaan baru menggunakan *top 10 models*

Id	Loss	Accuracy	Model	Augmentasi	Freeze	Learning Rate	Layer	Optimizer	Test	Time (min)	Epoch
66	0.29	0.91	Inception	Yes	None	0.0001	1	Adam	1	38	14
63	0.56	0.88	Inception	Yes	None	0.001	1	Adam	0.996	74	27
111	0.54	0.85	Xception	Yes	None	0.001	1	Adam	0.9881	52	12
...
138	1.57	0.56	Xception	No	None	0.0001	1	Adam	0.9901	11	11
110	2.19	0.54	Xception	Yes	$\frac{1}{2}$	0.001	1	Adam	0.9871	23	8
75	1.99	0.43	Inception	No	None	0.001	1	SGD	0.9901	28	50


4.7.3.2. Menggunakan top 3 models berdasarkan nilai parameter freeze

Tabel 4.5 Rincian hasil percobaan baru menggunakan *top 3 models*

Id	Loss	Accuracy	Model	Augmentasi	Freeze	Learning Rate	Layer	Optimizer	Test	Time (min)	Epoch
66	0.29	0.91	Inception	Yes	None	0.0001	1	Adam	1	38	14
63	0.56	0.88	Inception	Yes	None	0.001	1	Adam	0.996	74	27
3	0.52	0.84	VGG	Yes	None	0.001	1	SGD	0.9921	50	13
...
70	4.11	0.10	Inception	Yes	Full	0.0001	2	Adam	0.7119	60	50
91	3.76	0.10	Inception	No	Full	0.001	2	Adam	0.7079	9	31
67	3.91	0.09	Inception	Yes	Full	0.001	2	Adam	0.7139	46	39


4.7.3.1. Analisis

Akurasi pengujian data baru terhadap top 10 models



Gambar 4.52 Rincian hasil percobaan baru menggunakan *top 10 models* dengan *bar-chart*

Akurasi pengujian data baru terhadap top 3 models (freeze)




Gambar 4.53 Rincian hasil percobaan baru menggunakan *top 3 models* dengan *bar-chart*

Bar-chart yang digambarkan di atas (**Gambar 4.52** dan **Gambar 4.53**) mewakili kinerja akurasi dari setiap model saat diuji kembali dengan data baru. Dari grafik tersebut, tampak bahwa dua model teratas dari pengujian *top 10 models* dan *top 3 models (freeze)* berasal dari model yang sama yaitu dari indeks 66 dan 63. Perbedaan hasil pengujian model terletak pada posisi ketiga dan seterusnya. Hasil pengujian dengan *top 3 models (freeze)* tidak menunjukkan perbandingan akurasi yang signifikan terhadap *top 10 models*. Bahkan, rata-rata akurasi yang diperoleh dari *top 3 models (freeze)* lebih rendah dibandingkan dengan *top 10 models*. Ini menunjukkan bahwa model-model yang dibuat tanpa nilai “None” (“½”, “Full”) untuk parameter *freeze* tidak menghasilkan kinerja yang sebanding dengan model yang dibuat dengan nilai “None”. Akurasi tertinggi yang dapat dihasilkan oleh model tanpa nilai “None” untuk parameter *freeze* adalah 83%, yang

berasal dari model VGG dengan true id 8 dan nilai parameter “½”. Berikut adalah analisis yang dilakukan pada *top 3 models (freeze)* dalam bentuk grafik untuk memperdalam performa masing-masing nilai parameter *freeze*.

Akurasi Maksimum terhadap Parameter Freeze




Gambar 4.54 Bar-chart performa maksimum masing – masing model berdasarkan parameter *freeze*


Hasil yang diperoleh dari **Gambar 4.54** mencerminkan informasi tentang akurasi maksimum yang dapat dicapai dari prediksi menggunakan data baru, berdasarkan masing-masing nilai parameter *freeze* dan dikelompokkan berdasarkan modelnya. Nilai maksimum yang dicapai dari parameter *full freeze* hanya mencapai 31% pada model Xception. Hal ini memvalidasi informasi yang diperoleh dari evaluasi hasil pengujian sebelumnya, yaitu bahwa fitur yang diperoleh dari *pre-trained model* yang dilatih dengan data ImageNet kurang sesuai dengan fitur yang dibutuhkan dalam kasus penelitian ini (citra tulis tangan aksara Jawa). Dalam konteks parameter *½ freeze*, model masih mampu mengenali 70-80% data baru

dengan akurat. Potensi untuk meningkatkan akurasi model dengan konteks tersebut masih ada, mengingat model yang dilatih dalam penelitian ini dibatasi hanya sampai 50 *epoch*. Untuk parameter *none freeze*, model Inception menunjukkan akurasi maksimum 91%, sedangkan model lainnya hanya mencapai akurasi 84%.


Penulis akan melakukan visualisasi prediksi dan evaluasi untuk mengetahui data seperti apa yang membuat model salah prediksi. Berikut adalah beberapa gambar visualisasi dilakukan dengan model id 66 yang merupakan model terbaik dari prediksi dengan data baru.



Gambar 4.55 Confusion matrix dengan model id 66



Gambar 4.56 Visualisasi prediksi 20 data secara acak



Gambar 4.57 Visualisasi prediksi 20 data yang salah secara acak

Setelah melakukan berbagai analisis berdasarkan **Gambar 4.55**, **Gambar 4.56**, dan **Gambar 4.57**. Penulis mengamati bahwa data yang diprediksi secara tidak tepat memiliki karakteristik sebagai berikut:

- **Tulisan aksara Jawa yang miring**, yang menyulitkan model untuk mengenali bentuk dan posisi huruf.
- **Tulisan yang tidak ditengah**, yang menyebabkan model untuk mengabaikan sebagian informasi pada gambar.
- **Tulisan yang terlalu kecil**, yang mengurangi resolusi dan kualitas gambar.
- **Tulisan aksara Jawa yang kurang rapi**, yang menimbulkan ambiguitas dan kesalahan dalam pengenalan huruf.

Untuk mengatasi masalah ini, penulis menyarankan untuk meningkatkan *preprocessing pipeline*, misalnya dengan menambahkan algoritma *cropping* yang dapat menyesuaikan ukuran dan posisi huruf secara otomatis. Selain itu, penulis juga menyarankan untuk mengevaluasi dan menyesuaikan *config augmentasi*, agar data *training* lebih mencerminkan variasi dan kondisi data *testing* di dunia nyata. Secara umum, penulis berpendapat bahwa peningkatan performa model dapat dicapai dengan menambahkan data baru yang lebih beragam dan representatif sesuai dengan data di dunia nyata.

BAB V

PENUTUP

5.1. Kesimpulan

Berdasarkan serangkaian proses pengujian dan analisis yang telah dilakukan pada bab sebelumnya, dapat ditarik beberapa kesimpulan sebagai berikut:

1. Dari ketiga model yang diuji, yaitu VGG16, Inception V3, dan Xception, model Inception V3 menunjukkan performa terbaik secara keseluruhan ditinjau dari sisi akurasi *testing*, waktu komputasi (38 menit), dan kestabilan hasil.
2. Nilai akurasi tertinggi yang dicapai mencapai 100% pada data *testing*. Namun, ketika diuji dengan data baru di luar data latih, akurasi turun hingga sekitar 90%. Hal ini tidak buruk, mengingat pelatihan model dilakukan dengan data citra huruf tulis tangan aksara Jawa digital, sedangkan untuk pengujian model dengan data baru, berasal dari data citra tulis tangan aksara Jawa non-digital.
3. Nilai parameter *freeze* yang paling cocok untuk kasus ini adalah “None” yaitu melatih kembali keseluruhan arsitektur model di bagian *feature extractor*. Hal ini bisa terjadi dikarenakan fitur yang didapat pada *pre-trained model* kurang sesuai.
4. Parameter augmentasi data, pembekuan lapisan model (*freeze layer*), dan *optimizer* memiliki pengaruh yang signifikan terhadap performa model.

5. Dalam tahap pelatihan model, parameter yang berdampak signifikan terhadap waktu penyelesaian pelatihan adalah augmentasi, pembekuan lapisan model (*freeze layer*), *optimizer*, dan *learning rate*.

5.2. Saran

Berdasarkan penelitian yang telah dilakukan, terdapat beberapa saran untuk pengembangan lebih lanjut, yaitu:

1. Memperbanyak variasi data latih dengan menggunakan lebih banyak sumber tulisan tangan dari penulis yang berbeda. Data latih sebaiknya mencakup berbagai gaya tulisan dan kondisi pencahayaan.
2. Melakukan augmentasi data secara lebih luas, seperti *shear* dan *translation* untuk merepresentasikan data dunia nyata.
3. Mengexplorasi *state of the art* (SOTA) *image classification model* yang lebih mutakhir seperti Vision Transformer dan BASIC-L.
4. Melakukan *hyperparameter tuning optimization* dengan grid search, random search, bayesian search, atau lainnya untuk menemukan konfigurasi parameter yang optimal.
5. Mengembangkan model deteksi untuk mendeteksi lokasi huruf sebelum klasifikasi agar dapat menangani input gambar yang lebih kompleks.
6. Mengimplementasikan model pada platform *mobile* atau web agar dapat dimanfaatkan pengguna secara luas.

DAFTAR PUSTAKA

- Abadi, M., Agarwal, A., Barham, P., Brevdo, E., Chen, Z., Citro, C., Corrado, G. S., Davis, A., Dean, J., Devin, M., Ghemawat, S., Goodfellow, I., Harp, A., Irving, G., Isard, M., Jia, Y., Jozefowicz, R., Kaiser, L., Kudlur, M., ... Research, G. (2016). *TensorFlow: Large-Scale Machine Learning on Heterogeneous Distributed Systems*. <https://arxiv.org/abs/1603.04467v2>
- Abdul Robby, G., Tandra, A., Susanto, I., Harefa, J., & Chowanda, A. (2019). Implementation of Optical Character Recognition using Tesseract with the Javanese Script Target in Android Application. *Procedia Computer Science*, 157, 499–505. <https://doi.org/10.1016/J.PROCS.2019.09.006>
- Ahmed, R. M., Rashid, T. A., Fattah, P., Alsadoon, A., Bacanin, N., Mirjalili, S., Vimal, S., & Chhabra, A. (2022). Kurdish Handwritten character recognition using deep learning techniques. *Gene Expression Patterns*, 46, 119278. <https://doi.org/10.1016/J.GEP.2022.119278>
- Burkov, A. (2019). The Hundred-Page Machine Learning Book. Andriy Burkov.
- Buslaev, A., Iglovikov, V. I., Khvedchenya, E., Parinov, A., Druzhinin, M., & Kalinin, A. A. (2020). Albumentations: Fast and flexible image augmentations. *Information (Switzerland)*, 11(2). <https://doi.org/10.3390/INFO11020125>
- Chandrarathne, G., Thanikasalam, K., & Pinidiyaarachchi, A. (2020). A Comprehensive Study on Deep Image Classification with Small Datasets.

- Lecture Notes in Electrical Engineering, 619, 93–106.*
https://doi.org/10.1007/978-981-15-1289-6_9/COVER
- Chollet, F. (2016). Xception: Deep Learning with Depthwise Separable Convolutions. *Proceedings - 30th IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2017, 2017-January*, 1800–1807.
<https://doi.org/10.1109/CVPR.2017.195>
- Chollet, F. (2021). Deep Learning with Python (2nd ed.). Manning Publications Co.
- Deng, J., Dong, W., Socher, R., Li, L.-J., Kai Li, & Li Fei-Fei. (2010). *ImageNet: A large-scale hierarchical image database*. 248–255.
<https://doi.org/10.1109/CVPR.2009.5206848>
- Everson, M. (2008, March 6). Proposal for encoding the Javanese script in the UCS (N3319R3) [PDF]. ISO/IEC JTC1/SC2/WG2. Unicode.
- G., A. R., Tandra, A., Susanto, I., Harefa, J., & Chowanda, A. (2019). Implementation of Optical Character Recognition using Tesseract with the Javanese Script Target in Android Application. *Procedia Computer Science*, 499-505.
- Gonzalez, R. C., & Woods, R. E. (2018). Digital Image Processing (4th ed., Global ed.). Harlow, England: Pearson Education Limited.
- He, K., Zhang, X., Ren, S., & Sun, J. (2015). Deep Residual Learning for Image Recognition. *Proceedings of the IEEE Computer Society Conference on*

- Computer Vision and Pattern Recognition, 2016-December*, 770–778.
<https://doi.org/10.1109/CVPR.2016.90>
- Iman, M., Rasheed, K., & Arabnia, H. R. (2022). A Review of Deep Transfer Learning and Recent Advancements. *Technologies*, 11(2), 40.
<https://doi.org/10.3390/technologies11020040>
- Kesaulya, G. N. A., Fariza, A., & Karlita, T. (2022). Javanese Script Text Image Recognition Using Convolutional Neural Networks. *IES 2022 - 2022 International Electronics Symposium: Energy Development for Climate Change Solution and Clean Energy Transition, Proceeding*, 534–539.
<https://doi.org/10.1109/IES55876.2022.9888527>
- Lecun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature* 2015 521:7553, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- Li, Z., Liu, F., Yang, W., Peng, S., & Zhou, J. (2022). A Survey of Convolutional Neural Networks: Analysis, Applications, and Prospects. *IEEE Transactions on Neural Networks and Learning Systems*, 33(12), 6999–7019.
<https://doi.org/10.1109/TNNLS.2021.3084827>
- Perez, F., Vasconcelos, C., Avila, S., & Valle, E. (2018). Data Augmentation for Skin Lesion Analysis. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, 11041 LNCS, 303–311. https://doi.org/10.1007/978-3-030-01201-4_33
- Poerwadarminta, W.J.S. (1939). Baoesastra Djawa (dalam bahasa Jawa). J.B. Wolters.

- Ranjan, C. (2019). Understanding Deep Learning: Application in Rare Event Prediction. Chitta Ranjan.
- Rizky, A. F., Yudistira, N., & Santoso, E. (2023). *Text recognition on images using pre-trained CNN*. <https://arxiv.org/abs/2302.05105v1>
- Saponara, S., & Elhanashi, A. (2022). Impact of Image Resizing on Deep Learning Detectors for Training Time and Model Performance. *Lecture Notes in Electrical Engineering, 866 LNEE*, 10–17. https://doi.org/10.1007/978-3-030-95498-7_2/COVER
- Simonyan, K., & Zisserman, A. (2014). Very Deep Convolutional Networks for Large-Scale Image Recognition. *3rd International Conference on Learning Representations, ICLR 2015 - Conference Track Proceedings*. <https://arxiv.org/abs/1409.1556v6>
- Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., Erhan, D., Vanhoucke, V., & Rabinovich, A. (2015). Going deeper with convolutions. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 07-12-June-2015*, 1–9. <https://doi.org/10.1109/CVPR.2015.7298594>
- Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., & Wojna, Z. (2016). Rethinking the Inception Architecture for Computer Vision. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2016-December*, 2818–2826. <https://doi.org/10.1109/CVPR.2016.308>
- Tammina, S. (2019). Transfer learning using VGG-16 with Deep Convolutional Neural Network for Classifying Images. *International Journal of Scientific*

and Research Publications (IJSRP), 9(10), p9420.

<https://doi.org/10.29322/IJSRP.9.10.2019.P9420>

Torrey, L., & Shavlik, J. (2009). Chapter: Transfer Learning. Hershey, Pennsylvania: IGI Global.

U, M. K., Sihabuddin, A., & S.Si., M.Kom., Dr. (n.d.). Transfer learning implementation on Sundanese script recognition using convolutional neural network (Bachelor's thesis).

Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). How transferable are features in deep neural networks? *Advances in Neural Information Processing Systems*, 4(January), 3320–3328.

<https://arxiv.org/abs/1411.1792v1>

Zaccone, G., & Karim, M. R. (2018). Deep Learning with TensorFlow: Explore neural networks and build intelligent systems with Python (2nd ed.). Birmingham, United Kingdom: Packt Publishing.